Semana 15 - Etapa 6. Conocimiento oculto

Andrés F. Rodríguez
Jonathan D. Chavarro
Grupo Wololo

Facultad de Ingeniería, Ingeniería de sistemas y computación
Universidad de Cundinamarca, Chía, Cundinamarca

Minería de Datos – 901N
Docente Edison Gustavo Canon Varela

13 de nov de 2026

Contenido

1. Contexto, objetivo y preguntas de análisis 3
2. Datos y transformaciones adicionales 3
3. Herramientas y flujos de Orange 4
4. Modelos supervisados 6
   4.1. Pregunta, variable objetivo y tipo de problema 6
   4.2. Preparación y selección de variables 6
   4.3. Modelos y parámetros 7
   4.4. Estrategia de evaluación 7
   4.5. Resultados y comparación 8
   4.6. Modelo seleccionado y justificación 10
5. Modelo no supervisado: clustering 10
   5.1. Pregunta y variables 10
   5.2. Normalización y parámetros 11
   5.3. Elección del número de grupos 11
   5.4. Caracterización de los grupos 12
   5.5 Patrones ocultos y decisión 13
6. Extracción y análisis de comentarios de YouTube 13
   6.1. Propósito y conexión a la API 13
   6.2. Criterios de búsqueda y videos 13
   6.3. Extracción y restricciones 13
   6.4. Preparación y limpieza 14
   6.5. Flujo de minería de texto en Orange 14
   6.6. Resultados 14
   6.7. Aporte frente al EVA y límites 16
7. Conclusiones integradas 16
8. Limitaciones 17
9. Integración en Flask y reproducción 17
10. Enlaces del proyecto 18
11. Referencias 19

Semana 15 - Etapa 6. Conocimiento oculto

1. Contexto, objetivo y preguntas de análisis

Contexto. El proyecto estudia la seguridad alimentaria y la producción agrícola en Colombia a partir de las Evaluaciones Agropecuarias Municipales (EVA) de seis cultivos básicos (maíz, arroz, papa, plátano, yuca y frijol), 2019–2024, en 1.098 municipios de 32 departamentos. El conjunto quedó depurado en las etapas R2/R3 (48.932 registros) y fue analizado de forma descriptiva (R4, conocimiento evidente) y multidimensional (R5, modelo estrella OLAP). Hallazgos previos clave: el maíz tradicional del Caribe tiene bajo rendimiento y la Orinoquía produce mucho volumen con pocos registros.

Objetivo. Descubrir patrones, relaciones y comportamientos que expliquen dónde y por qué el rendimiento agrícola queda por debajo de su referente, mediante modelos de aprendizaje supervisado y no supervisado en Orange Data Mining, y complementarlos con el análisis de comentarios extraídos con la API de YouTube, más allá de los resultados descriptivos y multidimensionales.

Preguntas de análisis:

- **Supervisado.** ¿Un registro (municipio × desagregación de cultivo × semestre) tendrá un rendimiento por encima de la mediana de su cultivo, usando solo lo que se sabe antes de cosechar? → clasificación binaria.
- **Clustering.** ¿Qué tipos de municipio agrícola existen según su tamaño, su mezcla de cultivos y la parte de lo sembrado que cosechan? → k-Means.
- **Comentarios.** ¿Qué factores asocian quienes comentan con producir y acceder a alimentos básicos, y cómo se relacionan con lo que muestra el EVA?

2. Datos y transformaciones adicionales

Fuente. EVA — Evaluaciones Agropecuarias Municipales (MinAgricultura/UPRA, datos.gov.co), ya depurada en R2/R3. URL: https://www.datos.gov.co/Agricultura-y-Desarrollo-Rural/Evaluaciones-Agropecuarias-Municipales-EVA-2019-20/uejq-wxrr

Sobre los datos depurados se aplicaron transformaciones adicionales para habilitar los modelos (script scripts/R6/preparar_datos_orange.py; bitácora en orange/data/log_preparacion.json):

Transformación	Detalle	Registros
Exclusión de registros sin cosecha	Área cosechada, producción y rendimiento en 0 (el rendimiento no está definido).	48.932 → 46.634
Exclusión de área incoherente	Área cosechada > área sembrada (bandera de R2; el área sembrada se usa como predictor y no es confiable).	46.634 → 39.934

Variables nuevas	RendimientoAlto (clase), Log10_AreaSembrada, Semestre, GrupoCV (= municipio).	—
Variables por municipio	Área anual, número de cultivos, diversificación (1 − Herfindahl), % de área por cultivo y tasa de cosecha.	1.098 municipios

Archivos generados: eva_supervisado.csv, eva_supervisado_entrenamiento_2019_2023.csv, eva_supervisado_prueba_2024.csv y eva_municipios.csv.

3. Herramientas y flujos de Orange

Se utilizó Orange Data Mining 3.40 (complemento Text 1.16.3), Python, la YouTube Data API v3 y Flask. Se construyeron tres flujos de trabajo (.ows), uno por cada análisis:

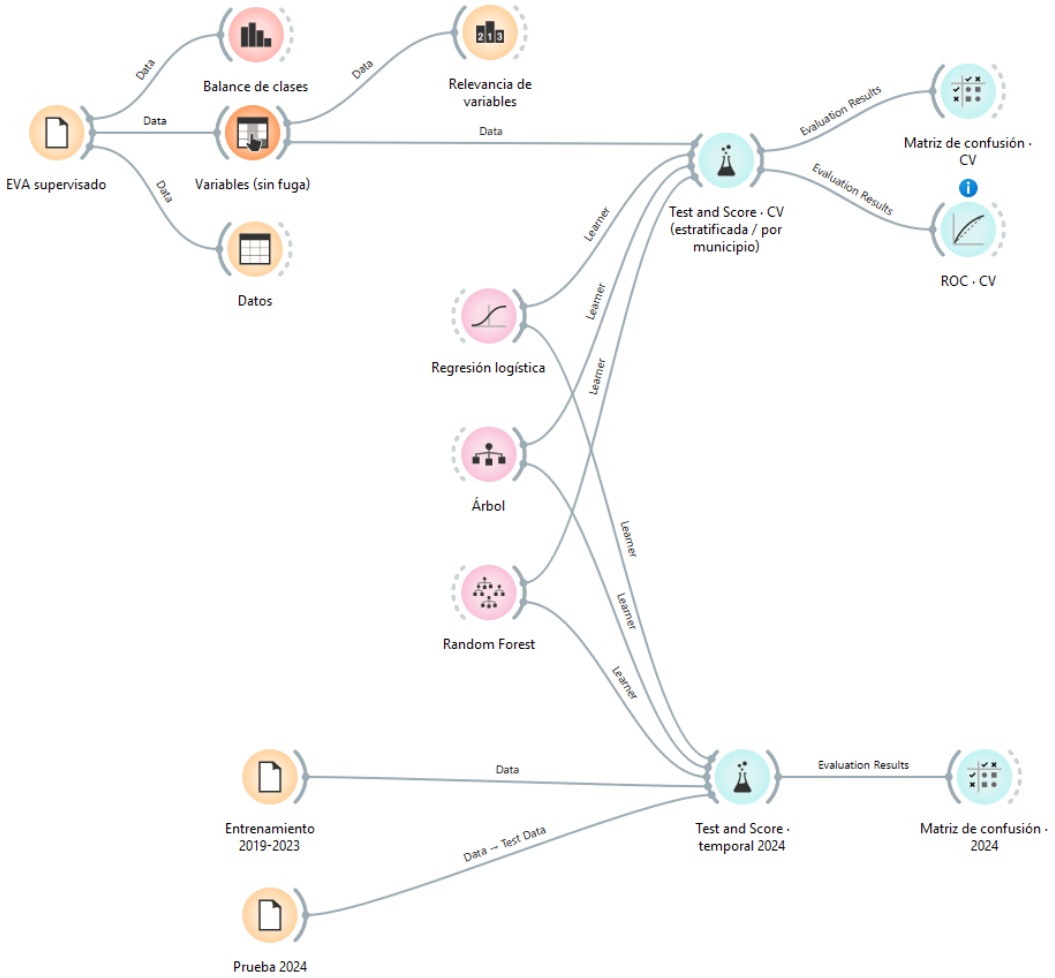


Figura 1. Flujo de trabajo supervisado en Orange (01_supervisado.ows): clasificación binaria del rendimiento agrícola.

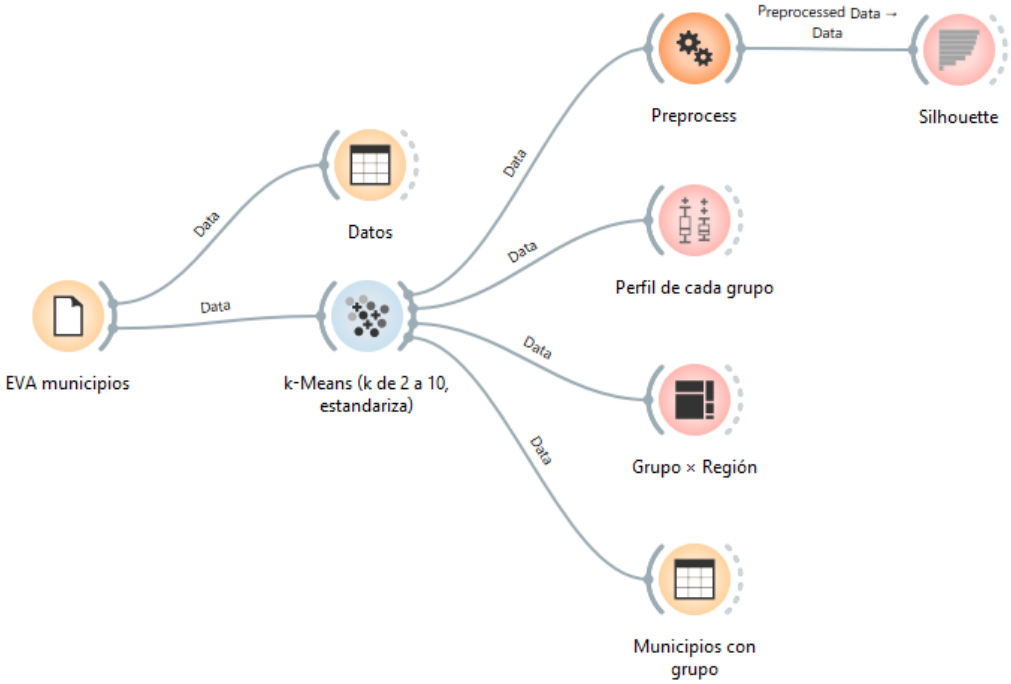


Figura 2. Flujo de trabajo de clustering en Orange (02_clustering.ows): agrupamiento de municipios con k-Means.

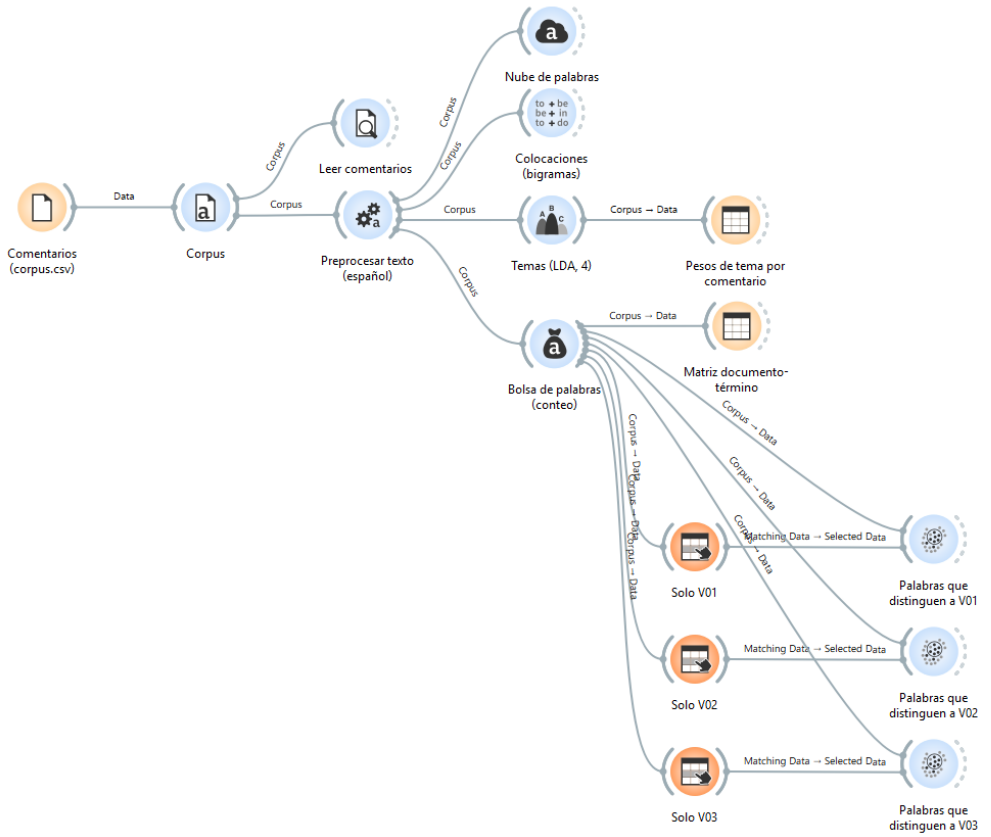


Figura 3. Flujo de minería de texto en Orange (03_comentarios_youtube.ows): análisis de los comentarios extraídos de YouTube.

4. Modelos supervisados

4.1. Pregunta, variable objetivo y tipo de problema

Problema. Clasificación binaria. La clase RendimientoAlto = Alto si el rendimiento supera la mediana 2019–2023 de su cultivo (umbrales en t/ha: arroz 4,8 · frijol 1,3 · maíz 1,8 · papa 17,0 · plátano 7,0 · yuca 10,0). El umbral se calcula sin 2024 para que la prueba no influya en la etiqueta.

Por qué clasificación. El rendimiento depende sobre todo del cultivo (papa 17 t/ha frente a frijol 1,3 t/ha). Comparar con el referente de cada cultivo da un umbral común y responde la decisión que interesa: ¿este registro quedará por debajo de lo normal?

4.2. Preparación y selección de variables

Predictoras. Cultivo, DesagregacionCultivo, Region, Departamento, Semestre y Log10_AreaSembrada.

Excluidas por fuga de información. Produccion, AreaCosechada y Rendimiento (solo se conocen después de cosechar). Metadatos que no predicen: CodMunicipio, Municipio, Anio y GrupoCV.

Balance de clases. 39.934 registros: 47,3 % Alto (18.886) y 21.048 Bajo. Casi balanceado, por lo que la exactitud es interpretable; aun así se reportan F1, precisión y recall de la clase Alto.

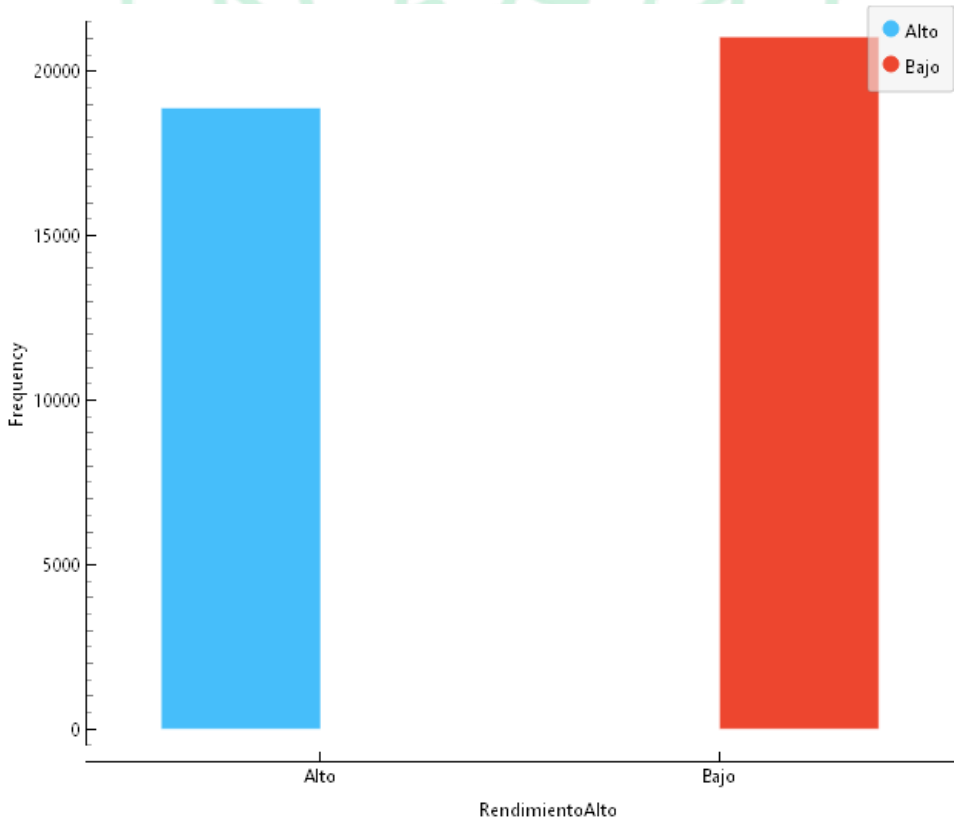


Figura 4. Balance de la clase Rendimiento Alto: 18.886 registros Alto (47,3 %) y 21.048 Bajo.

4.3. Modelos y parámetros

Modelo	Parámetros
Regresión logística	Regularización Ridge (L2), C = 1.
Árbol de decisión	Sin binarización (Departamento tiene 32 valores); profundidad máx. 12; mínimo 20 por hoja; mínimo 50 para dividir.
Random Forest	100 árboles; mínimo 5 para dividir; semilla fija.

Flujo: File → Select Columns → (3 learners) → Test and Score (CV) y Test and Score (temporal) → Confusion Matrix y ROC Analysis; además Distributions (balance de clases) y Rank.

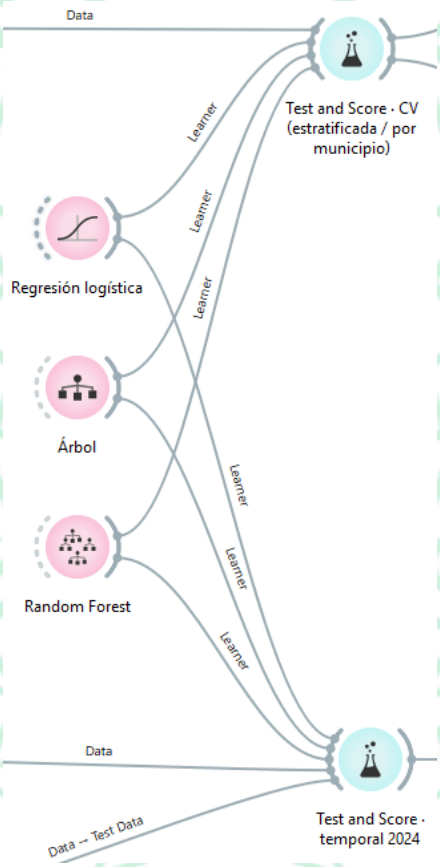


Figura 5. Configuración del flujo supervisado: tres modelos evaluados bajo las mismas condiciones.

4.4. Estrategia de evaluación

Los tres modelos se evaluaron en igualdad de condiciones (clase objetivo = Alto), con tres estrategias que evitan la fuga de la variable objetivo:

- Validación cruzada estratificada de 10 pliegues.
- Validación cruzada por municipio (Cross validation by feature = GrupoCV).

- Temporal: entrenar con 2019–2023 (34.242 registros) y probar con 2024 (5.692).

4.5. Resultados y comparación

Métricas (AUC / exactitud / F1 / precisión / recall; clase objetivo = Alto):

Estrategia / Modelo	AUC	Exactitud	F1	Precisión	Recall
CV estratificada — Reg. logística	0,738	0,668	0,615	0,682	0,560
CV estratificada — Árbol	0,788	0,711	0,687	0,703	0,672
CV estratificada — Random Forest	0,797	0,723	0,700	0,716	0,685
CV por municipio — Reg. logística	0,729	0,661	0,606	0,672	0,551
CV por municipio — Árbol	0,721	0,655	0,626	0,642	0,611
CV por municipio — Random Forest	0,691	0,632	0,607	0,614	0,600
Temporal 2024 — Reg. logística	0,741	0,677	0,606	0,692	0,540
Temporal 2024 — Árbol	0,691	0,641	0,586	0,625	0,552
Temporal 2024 — Random Forest	0,805	0,729	0,697	0,720	0,676

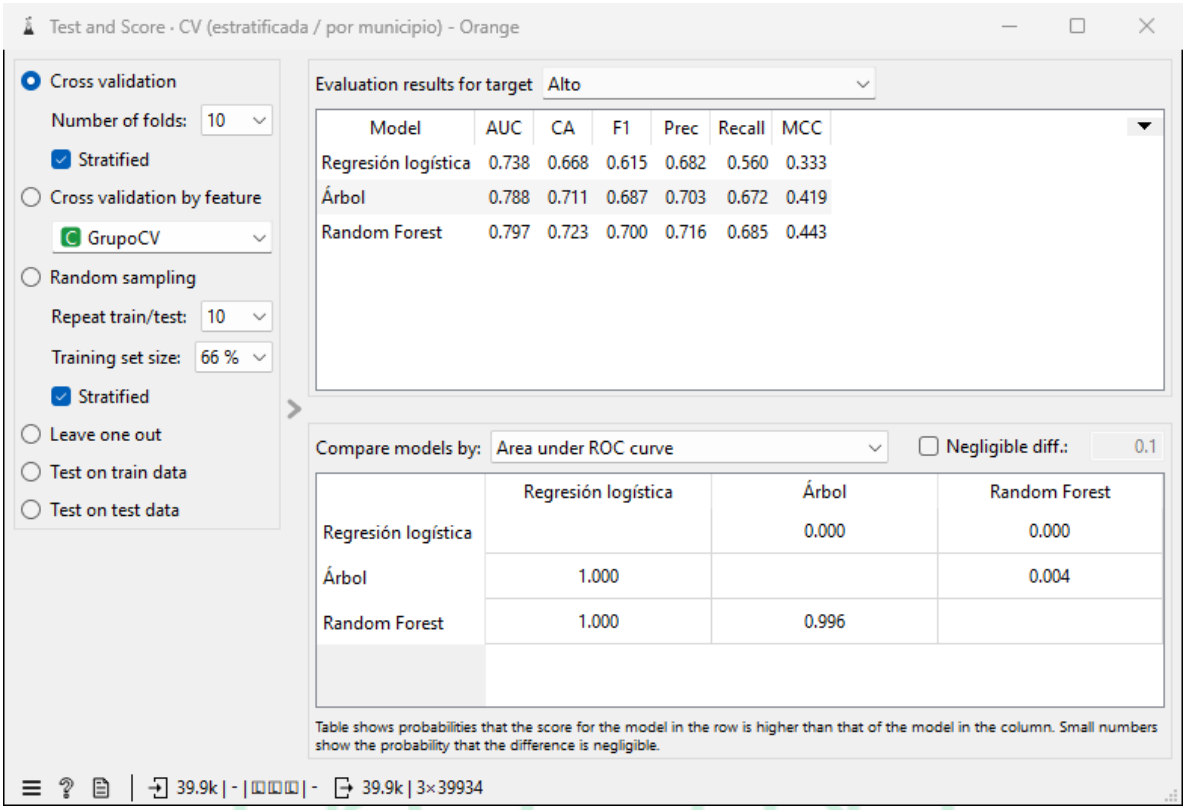


Figura 6. Comparación de los tres modelos en las tres estrategias de validación.

Matrices de confusión de Random Forest (filas = valor real):

Prueba 2024	Predicho Alto	Predicho Bajo	Total
Alto real	1.776 (67,6 %)	852 (32,4 %)	2.628
Bajo real	689 (22,5 %)	2.375 (77,5 %)	3.064

CV por municipio	Predicho Alto	Predicho Bajo
Alto real	11.326	7.560
Bajo real	7.134	13.914

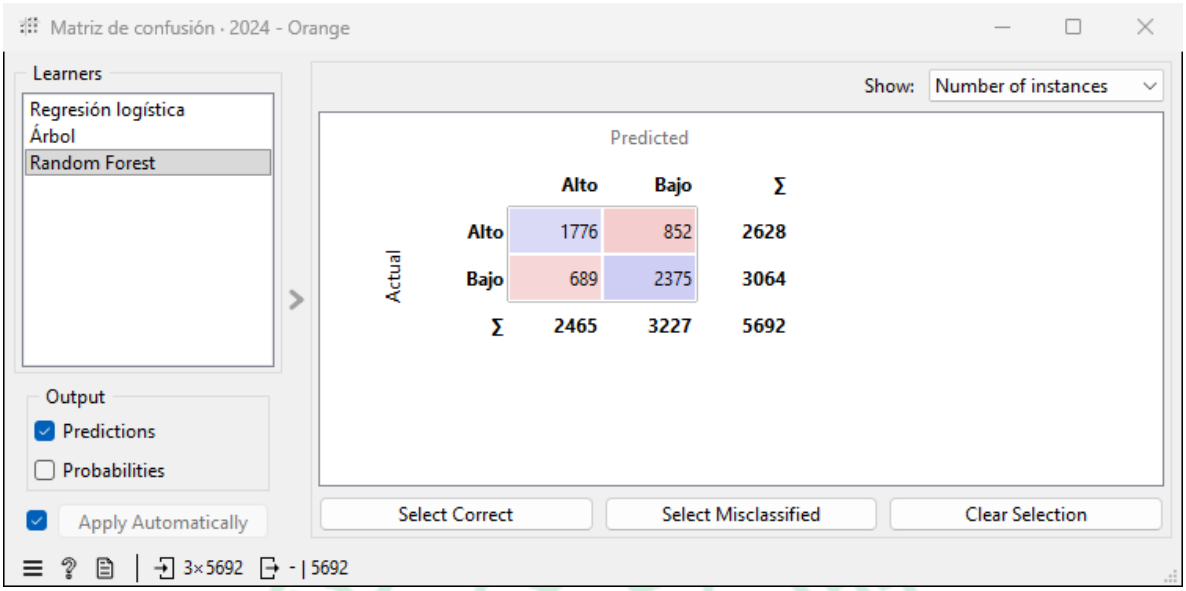


Figura 7. Matriz de confusión del modelo seleccionado: su error más frecuente es predecir Bajo cuando fue Alto.

4.6. Modelo seleccionado y justificación

Selección: Random Forest. El uso realista es anticipar, al inicio de la temporada, qué registros de municipios que ya reportan al EVA quedarán por debajo de lo normal. Los 1.098 municipios aparecen todos los años, así que la evaluación temporal 2024 es la que reproduce ese uso, y ahí RF es el mejor en todas las métricas (AUC 0,805). Su error más frecuente es predecir Bajo cuando fue Alto (852): es conservador, lo que conviene para alertas tempranas.

Qué aporta. El rendimiento relativo tiene "memoria territorial": el municipio, el departamento y el sistema productivo lo anticipan.

Limitaciones. Con municipios no vistos el AUC baja a 0,691 y la regresión logística queda primera (además es más interpretable). El modelo no incluye clima, suelos, precios ni insumos; es una asociación, no una causa.

5. Modelo no supervisado: clustering

5.1. Pregunta y variables

Pregunta: ¿qué tipos de municipio agrícola existen según su tamaño, su mezcla de cultivos y la parte de lo sembrado que cosechan? Se usan 1.098 municipios y 10 variables: Log10_AreaSembradaAnual, NumCultivos, Diversificacion, PctArea de (Arroz, Frijol, Maíz, Papa, Plátano, Yuca) y TasaCosecha. No entra ninguna variable de rendimiento; RendRelMediano (rendimiento / mediana del cultivo) es un metadato que solo se usa para **describir los grupos.**

5.2. Normalización y parámetros

Normalización. Estandarización (μ = 0, σ = 1), porque las escalas son muy distintas (log, 0–100, 0–1).

Algoritmo. k-Means (k-means++, 10 reinicios, 300 iteraciones máximo), probando k de 2 a 10. Flujo: Preprocess (Standardize) → k-Means → Silhouette Plot (Grouping = Cluster) y Mosaic Display Cluster × Región ($\chi^2 = 482$, $p < 0{,}001$).

5.3. Elección del número de grupos

Silueta por k: 2 = 0,253 · 3 = 0,214 · 4 = 0,242 · 5 = 0,272 · 6 = 0,265 · 7 = 0,253 · 8 = 0,250 · 9 = 0,233 · 10 = 0,215. Se elige k = 5 (máximo). La silueta es baja (< 0,3): los grupos se solapan y deben leerse como tendencias, no como segmentos nítidos.

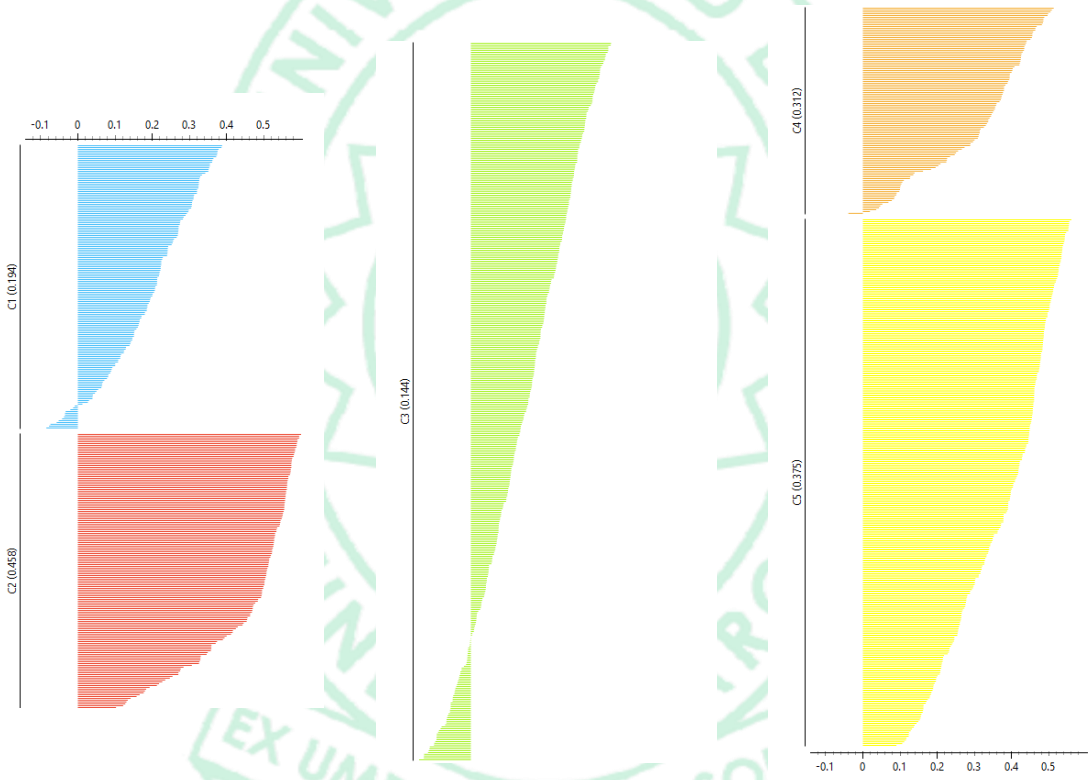


Figura 8. La silueta máxima en k = 5 justifica el número de grupos; los valores < 0,3 indican solapamiento.

5.4. Caracterización de los grupos

Grupo	Municipio	Cultivo dominante	Área anual (ha)	Tasa cosecha	Rend. rel.	Regiones	Silueta
G1 Arroceros de gran escala	113	arroz 70 %	3.896	0,81	1,15	Andina 42 %, Orinoquía 27 %, Caribe 25 %	0,312
G2 Andinos pequeños (frijol/maíz)	155	frijol 46 %, maíz 27 %	281	0,84	0,92	Andina 91 %	0,194
G3 Mixtos campesinos (maíz/yuca)	392	maíz 44 %, yuca 27 %	715	0,82	0,98	Caribe 42 %, Andina 37 %	0,144
G4 Paperos del altiplano	150	papa 86 %	563	0,86	1,07	Andina 97 %	0,458
G5 Plataneros (alta tasa de cosecha)	288	plátano 73 %	660	0,92	0,94	Andina 73 %, Pacífica 17 %	0,375

Área anual en media geométrica. G3 presenta un 17 % de municipios con silueta < 0 (mezcla); G4 es el grupo más compacto.

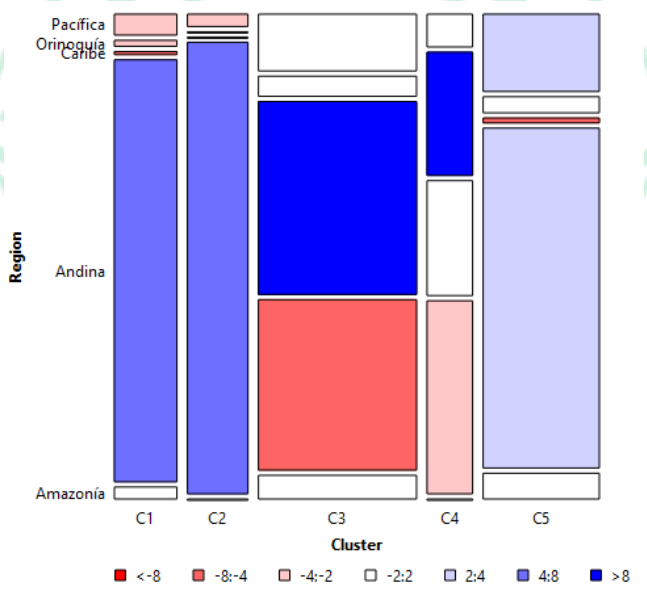


Figura 9. Asociación entre los grupos y las regiones naturales ($\chi^2 = 482$, $p < 0{,}001$) y perfiles medios.

5.5 Patrones ocultos y decisión

Patrones. Los municipios especializados (arroz, papa) rinden por encima de la mediana; los diversificados de pequeña escala (G2, G3) rinden por debajo y cosechan menos de lo que siembran. Los arroceros siembran unas 14 veces el área del grupo más pequeño.

Decisión. Diseñar la asistencia técnica por tipo de municipio y no por departamento, con prioridad para G2 y G3.

6. Extracción y análisis de comentarios de YouTube

6.1. Propósito y conexión a la API

Propósito: identificar qué factores asocian los comentaristas con producir y acceder a alimentos básicos (insumos, precio al productor, clima, intermediarios) y contrastarlos con el EVA. La conexión se hace con la YouTube Data API v3 desde Google Cloud Console; la clave va en .env (YOUTUBE_API_KEY) y nunca se publica. Scripts: scripts/R6/extraer_comentarios_youtube.py; criterios en scripts/R6/youtube_config.json.

6.2. Criterios de búsqueda y videos

Criterios: 5 consultas (“precio de la papa Colombia campesinos”, “paro arrocero Colombia”, “costo de los insumos agrícolas Colombia”, “crisis del maíz Colombia importaciones”, “seguridad alimentaria Colombia”), 5 videos por consulta, región CO, idioma es, publicados desde 2022-01-01, mínimo 30 comentarios, orden por relevancia.

Video	Canal / fecha	Enlace	Extraídos / limpios
V01 Campesinos en Boyacá: crisis por el precio de la papa	Noticias Caracol, 2025-10-26	youtube.com/watch?v=3Qw6pcizxCs	73 / 67
V02 Paro arrocero paraliza 9 departamentos	Noticias Caracol, 2025-07-18	youtube.com/watch?v=SDR0xsgBQrg	50 / 47
V03 ¿Qué está pasando con el arroz en Colombia?	Economía para la pipol, 2025-03-13	youtube.com/watch?v=jd2Oth7H6Ss	89 / 81

6.3. Extracción y restricciones

Extracción: 2026-11-09. Cuota usada: 504 de 10.000 unidades. Restricciones: de 25 videos candidatos, 22 se descartaron por tener menos de 30 comentarios (muchos con 0 o con los comentarios desactivados). Solo se extrajeron comentarios principales (sin respuestas).

6.4. Preparación y limpieza

Limpieza (scripts/R6/preparar_comentarios.py): 212 → 195 comentarios. Pasos: 1 vacío; 9 irrelevantes (menos de 3 palabras); 0 duplicados; 7 en otro idioma (3 inglés, 4 otro). Se enmascaran URL, correos, @menciones y teléfonos. No se guarda autor, canal ni identificador; los comentarios crudos no se suben al repositorio.

6.5. Flujo de minería de texto en Orange

Archivo → Corpus (texto, español) → Preprocesar texto (minúsculas y quitar URL; tokenización por expresión regular \w+; filtrado antes de normalizar con una lista de 755 palabras vacías en español, sin números ni tokens de 1–2 letras, términos presentes en ≥ 2 comentarios; Snowball español) → Nube de palabras, Colocaciones (bigramas, frecuencia ≥ 2), Temas (LDA, 4), Bolsa de palabras → 3 Select Rows por video → Word Enrichment (FDR ≤ 0,2); además Corpus Viewer.

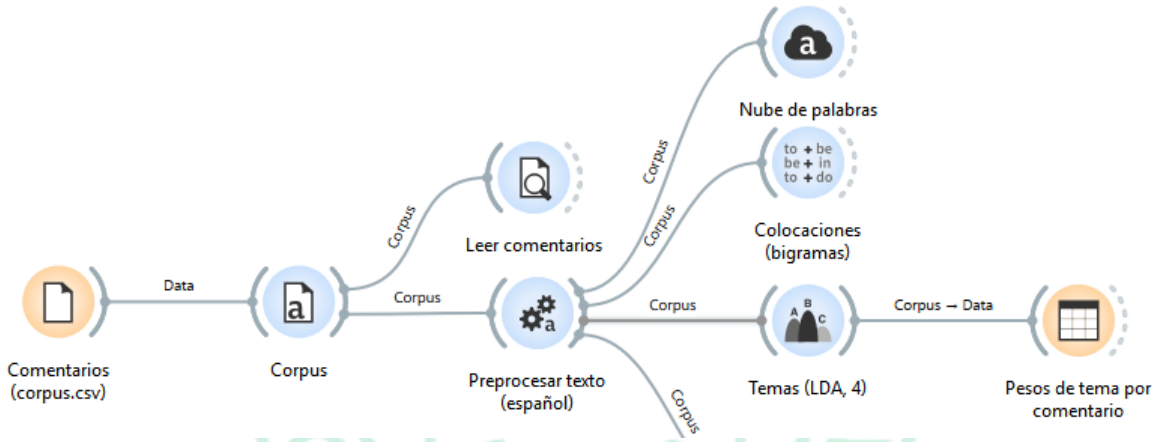


Figura 10. Flujo de procesamiento de texto que supera la nube de palabras: enriquecimiento por video y temas LDA.

6.6. Resultados

1.027 tokens, 203 términos. Términos más frecuentes (raíces): arroz 45, gobierno 41, campesino 35, precio 33, paro 23, producto 20, papa 18.

Word Enrichment. V01 (papa) → campesino, papa, intermediario, bulto, pesos, trabajo, cobrar, ganar. V02 (paro) → paro, cumplir, gobierno, pueblo, ministro. V03 (arroz) → solo "arroz" pasa FDR; TLC, barato, arancel y competitividad aparecen como tendencia (FDR ≈ 0,33).

LDA (4 temas; coherencia 0,372, baja, solo exploratoria). papa-campesino-intermediarios; paro y precio; precio del arroz (arroba, pesos); tema mixto (TLC, gobierno, agradecimientos). Colocaciones más repetidas: mil pesos, pobre campesino, paro arrocero, arroba de arroz, libre comercio.

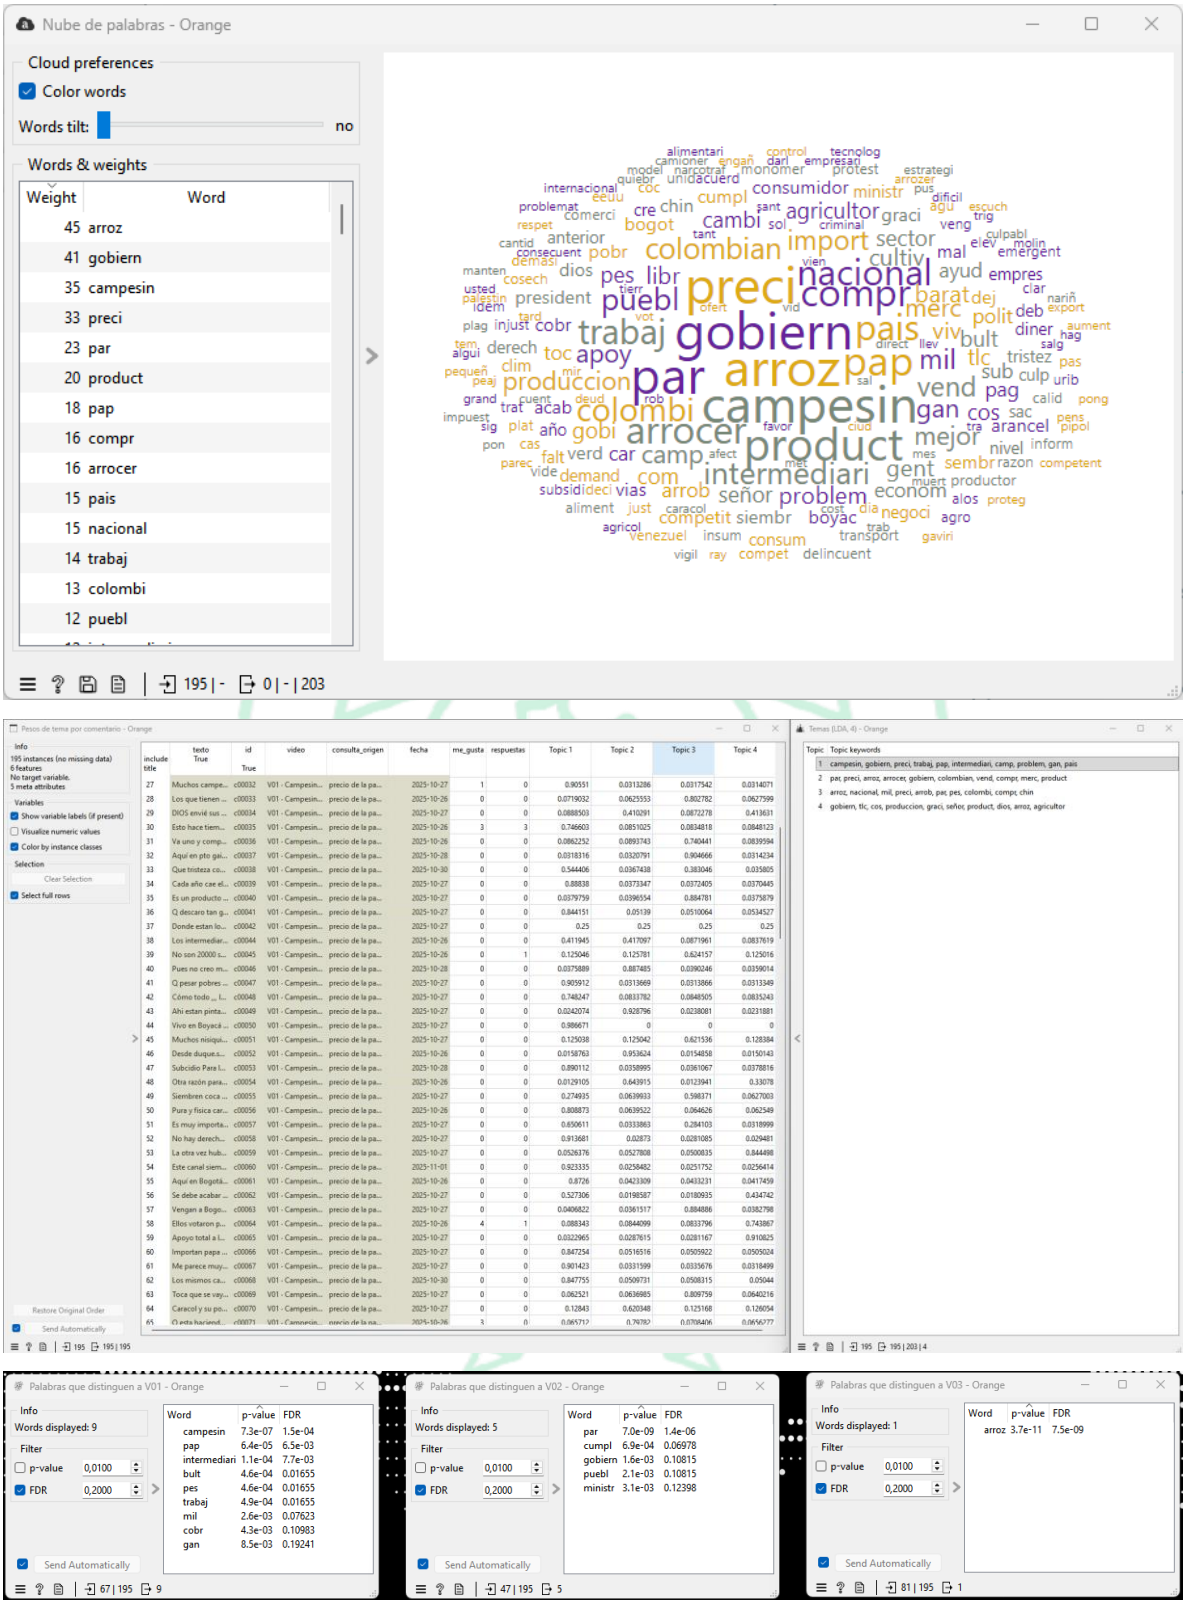


Figura 11. Términos y temas dominantes; las colocaciones y el enriquecimiento sustentan los hallazgos.

Factores asociados (diccionario de términos, % de comentarios; total / V01 / V02 / V03):

Factor	Total	V01 papa	V02 paro	V03 arroz
Gobierno y política	27,2 %	31,3 %	48,9 %	11,1 %
Precio productor vs consumidor	20,0 %	25,4 %	8,5 %	22,2 %
Importaciones y TLC	14,4 %	7,5 %	6,4 %	24,7 %
Subsidios y crédito	10,8 %	13,4 %	10,6 %	8,6 %
Intermediarios	8,2 %	17,9 %	4,3 %	2,5 %
Productividad y tecnología	8,2 %	1,5 %	0,0 %	18,5 %
Insumos y logística	5,6 %	9,0 %	4,3 %	3,7 %
Sobreproducción	3,6 %	7,5 %	2,1 %	1,2 %
Clima y plagas	2,1 %	3,0 %	0,0 %	2,5 %
Venta directa	1,0 %	1,5 %	0,0 %	1,2 %

6.7. Aporte frente al EVA y límites

Qué aportan. Ubican el problema en la comercialización (precio, intermediarios, importaciones) y en la relación con el gobierno, que el EVA no mide. En el video del arroz se habla de competir con el importado, mientras el EVA muestra que los municipios arroceros rinden por encima de la mediana (1,15): el reclamo es de precio, no de productividad. Clima y plagas casi no aparecen.

Límites. 195 comentarios de 3 videos (papa y arroz; 2 del mismo noticiero), con sesgo político. No representan a los productores ni a la población. El conteo de factores no detecta ironía ni negación.

7. Conclusiones integradas

Respaldado por evidencia:

- El rendimiento relativo es persistente por territorio: el modelo anticipa el año siguiente (AUC 0,805), pero no transfiere bien a municipios nuevos (0,691).
- Supervisado y clustering coinciden: especialización y escala (arroz, papa) van con rendimiento alto; los mixtos de pequeña escala, con rendimiento y tasa de cosecha menores. Coincide con R5 (maíz tradicional del Caribe, frijol andino).
- En los comentarios dominan el precio, los intermediarios, el gobierno y las importaciones por encima del clima o el rendimiento.

Hipótesis que requieren validación:

- Que el bajo rendimiento de los grupos mixtos se deba a tecnología o acceso a insumos (el EVA no tiene esas variables).
- Que el ingreso dependa más del precio que del rendimiento (harían falta precios SIPSA).
- Que los comentarios representen a los productores.

Decisiones:

- Usar el modelo como alerta temprana por municipio al inicio de cada semestre.
- Focalizar programas de productividad en los grupos mixtos de pequeña escala (G2, G3).
- Acompañar con instrumentos de comercialización (compras públicas, mercados campesinos).

8. Limitaciones

- El EVA no incluye clima, suelos, precios ni insumos: los modelos describen asociaciones, no causas.
- El modelo supervisado pierde desempeño con municipios no vistos (AUC 0,691).
- Las siluetas del clustering son bajas (< 0,3): los grupos son tendencias, no segmentos nítidos.
- Los comentarios (195 de 3 videos) tienen sesgo político y no representan a la población.

9. Integración en Flask y reproducción

Se agregó a la aplicación Flask la sección “Conocimiento oculto” (/r6) con la síntesis de hallazgos, métricas, matrices, grupos, videos, factores, conclusiones, el informe técnico (PDF) para consulta o descarga y el video de sustentación accesible por enlace.

El repositorio incorpora orange/flujos/*.ows, orange/data/, orange/README.md (guía de reproducción) y scripts/R6/. Pasos para reproducir:

- python scripts/R6/preparar_datos_orange.py
- Abrir los archivos .ows en Orange 3.40.
- Extraer, limpiar y contar factores con los scripts de YouTube.
- python scripts/R6/resultados_orange.py (genera los resultados para la app).



Figura 12. Integración web: síntesis de hallazgos, informe descargable y video de sustentación.

10. Enlaces del proyecto

Recurso	URL
Repositorio público (GitHub)	https://github.com/JODACHSE/Mineria-de-Datos
Aplicación web publicada (Render)	https://mineria-de-datos-4qn5.*onrender*.com/r6
Video de sustentación	https://youtu.be/kvMEUs-LW4k

11. Referencias

Ministerio de Agricultura y Desarrollo Rural / UPRA. Evaluaciones Agropecuarias Municipales (EVA) 2019–2024. Datos Abiertos Colombia, datos.gov.co.

DANE. División Político-Administrativa de Colombia (DIVIPOLA). dane.gov.co.

Demšar, J. et al. Orange: Data Mining Toolbox in Python. JMLR, 2013. orangedatamining.com.

Google. YouTube Data API v3 — Documentation. developers.google.com/youtube/v3.

Blei, D., Ng, A., Jordan, M. Latent Dirichlet Allocation. JMLR, 2003.