



UNIVERSIDAD DE CUNDINAMARCA

Programa académico: **[COMPLETAR — nombre del programa académico]**

Espacio académico: Minería de Datos

Informe técnico

Etapa 2 · Diagnóstico y Calidad de los Datos

Proyecto Wololo — Seguridad alimentaria y producción agrícola en Colombia (2000–2024)

Integrantes Jonathan David Chavarro Segura
(@JODACHSE)
Andrés Felipe Rodríguez Correa (@N3X4N)

Docente **[COMPLETAR — nombre del docente]**

Fecha 7 de septiembre de 2026

Rama de trabajo Feature/etapa-2 → main (Pull Request #1, mergeado)

Contenido

1. Introducción
2. Objetivo de la etapa
3. Descripción y propósito de los datos
4. Requisitos de calidad
5. Perfilamiento de los datos
6. Evaluación de las dimensiones de calidad
7. Inventario de problemas encontrados
8. Análisis de las causas
9. Integración y homologación de los datos
10. Plan de tratamiento
11. Implementación en Flask
12. Gestión en GitHub
13. Referencias bibliográficas
14. Enlaces del proyecto

1 • Introducción

El proyecto **Wololo** analiza la paradoja entre producción agrícola creciente e inseguridad alimentaria persistente en Colombia (2000–2024), cruzando datos municipales de producción (EVA, MinAgricultura/UPRA) con indicadores nacionales y globales de seguridad alimentaria y producción (FAOSTAT, FAO). En la Etapa 1 (R1) se seleccionaron y documentaron 8 fuentes de datos y se consolidó un dataset inicial de más de 59.700 registros reales.

Un dataset "real" —descargado de fuentes administrativas, no generado sintéticamente— trae consigo problemas de calidad que no siempre son evidentes a simple vista: campos con formato inconsistente, llaves de identificación mal definidas, valores atípicos, información desactualizada o divergencias entre fuentes que reportan el mismo fenómeno. Evaluar y tratar esa calidad no es un paso opcional: cualquier análisis o modelo posterior que se construya sobre datos sin diagnosticar hereda silenciosamente sus defectos. Esta etapa aplica un proceso sistemático de perfilamiento, medición en seis dimensiones, inventario de problemas y tratamiento real sobre los 4 datasets del proyecto, e integra los resultados directamente en la aplicación web para que sean verificables por cualquier usuario, no solo enunciados en un documento.

2 · Objetivo de la etapa

Aplicar los conceptos fundamentales de calidad de datos mediante el perfilamiento, diagnóstico, medición y tratamiento de los 4 datasets seleccionados en la etapa anterior, identificando problemas que puedan afectar su uso. Los resultados se integran en la aplicación web desarrollada con Flask (sección **Calidad de Datos**, ruta `/r2`), se publican en GitHub mediante una rama específica de la etapa y se despliegan en un servicio web.

3 · Descripción y propósito de los datos

Dataset	Fuente	Registros	Nivel	Variables principales
eva_basicos	EVA — MinAgricultura/UPRA	48.932	Municipal, 2019–2024	Departamento, municipio, cultivo, área sembrada/cosechada, producción, rendimiento
qc1	FAOSTAT (todos los productos)	9.274	Nacional, 2000–2024	Área, Producto, Elemento, Año, Unidad, Valor
qc1_basicos	FAOSTAT (6 cultivos básicos)	374	Nacional, 2000–2024	Igual esquema que qc1 , filtrado a 6 cultivos
fs	FAOSTAT (seguridad alimentaria)	1.138	Nacional/global, 2000–2024	Indicadores de subalimentación e inseguridad alimentaria

Uso esperado de la información: estos 4 datasets sostienen el análisis central del proyecto — comparar la producción agrícola municipal (EVA) contra los indicadores nacionales de seguridad alimentaria (FAOSTAT), agregando por cultivo, año y territorio, y cruzando ambas fuentes para detectar divergencias. Ese uso exige identificadores confiables (códigos DANE, no nombres), variables numéricas completas y dentro de rango, categorías homologadas entre EVA y FAOSTAT, y una vigencia razonable frente a la fecha del análisis — precisamente los requisitos que se definen a continuación.

4 • Requisitos de calidad

Umbral mínimo exigido por dimensión y dataset, definido según el uso previsto de la sección anterior (`app/quality.py::QUALITY_REQUIREMENTS`):

Dataset	Compleitud	Exactitud	Consistencia	Unicidad	Validez	Actualidad
eva_basicos	≥ 95%	≥ 95%	≥ 80%	≥ 99%	≥ 90%	≥ 60%
qcl	≥ 90%	≥ 70%	≥ 80%	≥ 99%	≥ 90%	≥ 60%
qcl_basicos	≥ 95%	≥ 70%	≥ 80%	≥ 99%	≥ 90%	≥ 60%
fs	≥ 90%	≥ 90%	≥ 80%	≥ 99%	≥ 90%	≥ 40%

El umbral de exactitud es más laxo para `qcl` / `qcl_basicos` (70%) porque su métrica se basa en el cruce EVA↔FAOSTAT, y la Etapa 1 ya documentó divergencias metodológicas reales de entre -21% y +216% entre esas dos fuentes — exigir 90%+ ahí negaría un hallazgo ya conocido, no sería un requisito realista. El umbral de actualidad de `fs` es más bajo (40%) porque los indicadores de seguridad alimentaria de FAO/SOFI tienen un rezago metodológico típico de 2–3 años mayor al de las estadísticas de producción.

5 • Perfilamiento de los datos

Implementado en `app/quality.py::profile_columns`, calculado **en vivo** (Python puro, sin precálculo) sobre cada dataset cargado como lista de diccionarios. Por columna calcula: tipo inferido, cantidad y % de nulos, cardinalidad, y — según el tipo declarado — mínimo, máximo, media, mediana, desviación estándar y valores atípicos ($\pm 1.5 \times$ rango intercuartílico) para numéricas, o los 5 valores más frecuentes para categóricas.

```
def profile_columns(rows: list[dict], columns: list[str], column_meta: dict) -> dict[str, dict]:
    """Perfilamiento por columna en una sola pasada (Python puro)."""
    n = len(rows)
    acc = {c: {"nulos": 0, "counter": Counter(), "numeric": []} for c in columns}
    for r in rows:
        for c in columns:
            v = r.get(c)
            if v in (None, "", "NaN"):
                acc[c]["nulos"] += 1
                continue
            acc[c]["counter"][v] += 1
            if column_meta.get(c, {}).get("tipo") == "numerico":
                fv = _to_float(v)
                if fv is not None:
                    acc[c]["numeric"].append(fv)
    # ... min/max/media/mediana/desviación/outliers_iqr por columna numérica,
    # top 5 valores por columna categórica, y conteo de fuera_de_rango /
    # fuera_de_dominio / no_conforme_patron cuando column_meta lo define.
```

eva_basicos (48.932 filas × 18 columnas)

Campo	Tipo	Nulos	Únicos	Detalle
CodigoDeptoDane / CodigoMunicipioDane	código	0	32 / 1.096	5.854 (11.96%) no conformes al patrón de ancho fijo
Departamento / Municipio	categórico / texto	0	32 / 1.106	—
Cultivo	categórico	0	6	Maíz, Arroz, Papa, Plátano, Yuca, Frijol
Anio	temporal	0	6	2019–2024
AreaSembrada	numérico	0	—	atípicos: 6.288 (12.85%)
AreaCosechada	numérico	0	—	atípicos: 6.505 (13.29%)

Campo	Tipo	Nulos	Únicos	Detalle
Produccion	numérico	0	—	atípicos: 7.368 (15.06%)
Rendimiento	numérico	0	—	atípicos: 3.342 (6.83%)

qcl (9.274 filas × 6 columnas)

Campo	Tipo	Nulos	Detalle
Área	categorico	0	único valor: "Colombia"
Unidad	categorico	0	toneladas, kg/ha, cabezas, 1000 cabezas, No., 1000 No., ...
Valor	numérico	280 (3.02%)	atípicos agrupados por (Producto, Elemento): 327 de 8.994 evaluables (3.64%)

qcl_basicos (374 filas): 0 nulos, atípicos agrupados 7 de 374 (1.87%). fs (1.138 filas): 0 nulos, atípicos agrupados 3 de 1.134 evaluables (0.26%).

2 · PERFILAMIENTO POR DATASET

Calculado en vivo (Python puro, sin precálculo) sobre la versión cruda de cada dataset (`app/quality.py::profile_columns`): cantidad de registros y variables, tipo inferido, valores únicos, nulos, y para variables numéricas mínimo, máximo, media y valores atípicos ($\pm 1.5 \times$ rango intercuartílico). Los campos con dominio/rango/patrón definido (p. ej. `Cultivo`, `CodigoMunicipioDane`) muestran además cuántos valores no conforman esa regla.

EVA – PRODUCCIÓN MUNICIPAL – 48.932 REGISTROS

CAMPO	TIPO	NULOS	ÚNICOS	DETALLE
CodigoDeptoDane	codigo	0 (0.0%)	32	5 (5008), 15 (4454), 25 (4345) 5854 NO CONFORME
Departamento	categorico	0 (0.0%)	32	Antioquia (5008), Boyacá (4454), Cundinamarca (4345)
CodigoMunicipioDane	codigo	0 (0.0%)	1098	41001 (94), 23001 (90), 23580 (88) 5854 NO CONFORME
Municipio	texto	0 (0.0%)	1016	La Unión (251), Granada (212), Bolivar (199)
GrupoCultivo	categorico	0 (0.0%)	4	Cereales (22628), Raices y tubérculos (13276), Leguminosas (8204)
Subgrupo	categorico	0 (0.0%)	4	Cereales (22628), Raices y tubérculos (13276), Leguminosas (8204)
Cultivo	categorico	0 (0.0%)	6	Maiz (18490), Yuca (8546), Frijol (8204)
DesagregacionCultivo	texto	0 (0.0%)	16	Frijol (8204), Yuca consumo en fresco (8182), Maiz amarillo tradicional (7340)
Anio	temporal	0 (0.0%)	6	2024 (8855), 2022 (8846), 2023 (8829)
Periodo	categorico	0 (0.0%)	18	2022A (4092), 2024A (4088), 2023A (4078)
AreaSembrada	numerico	0 (0.0%)	3348	min 0.0 · máx 40000.0 · media 272.607 · atipicos 6288 (12.85%)
AreaCosechada	numerico	0 (0.0%)	3460	min 0.0 · máx 37418.0 · media 256.79 · atipicos 6505 (13.29%)
Produccion	numerico	0 (0.0%)	9685	min 0.0 · máx 537575.0 · media 1994.122 · atipicos 7368 (15.06%)
Rendimiento	numerico	0 (0.0%)	1238	min 0.0 · máx 90.0 · media 5.603 · atipicos 3342 (6.83%)
CicloCultivo	categorico	0 (0.0%)	2	Transitorio (44108), Permanente (4824)
EstadoFisico	categorico	0 (0.0%)	3	Grano seco (22407), En fresco (22387), Paddy o cáscara verde (4138)
CodigoCultivo	codigo	0 (0.0%)	16	1060200 (8204), 1081001 (8182), 1010402 (7340)
NombreCientifico	texto	0 (0.0%)	7	Zea mays (18490), Manihot esculenta (8546), Phaseolus vulgaris (8204)

FAOSTAT – TODOS LOS PRODUCTOS – 9.274 REGISTROS

CAMPO	TIPO	NULOS	ÚNICOS	DETALLE
Código del ámbito	desconocido	0 (0.0%)	1	QCL (9274)
Ámbito	desconocido	0 (0.0%)	1	Cultivos y productos de ganaderia (9274)

Código del área	desconocido	0 (0.0%)	1	44 (9274)
Área	categorico	0 (0.0%)	1	Colombia (9274)
Código del elemento	desconocido	0 (0.0%)	14	5510 (3623), 5312 (2114), 5412 (1984)
Elemento	categorico	0 (0.0%)	8	Producción (3648), Área cosechada (2114), Rendimiento (2009)
Código del producto	desconocido	0 (0.0%)	168	1062 (125), 254 (75), 800 (75)
Producto	categorico	0 (0.0%)	168	Huevos de gallina con cáscara, frescos (125), Aceite, nuez de palma (75), Agave, fibras en bruto n.c.p. (75)
Código del año	desconocido	0 (0.0%)	25	2014 (384), 2015 (384), 2016 (384)
Año	temporal	0 (0.0%)	25	2014 (384), 2015 (384), 2016 (384)
Unidad	categorico	0 (0.0%)	10	toneladas (3623), ha (2114), kg/ha (1984)
Valor	numerico	280 (3.02%)	7353	min 0.0 · máx 40686856.0 · media 760733.115 · atipicos 1725 (19.18%)

FAOSTAT – CULTIVOS BÁSICOS – 374 REGISTROS

CAMPO	TIPO	MULOS	ÚNICOS	DETALLE
Código del ámbito	desconocido	0 (0.0%)	1	QCL (374)
Ámbito	desconocido	0 (0.0%)	1	Cultivos y productos de ganaderia (374)
Código del área	desconocido	0 (0.0%)	1	44 (374)
Área	categorico	0 (0.0%)	1	Colombia (374)
Código del elemento	desconocido	0 (0.0%)	2	5510 (199), 5412 (175)
Elemento	categorico	0 (0.0%)	2	Producción (199), Rendimiento (175)
Código del producto	desconocido	0 (0.0%)	8	27 (50), 176 (50), 56 (50)
Producto	categorico	0 (0.0%)	8	Arroz (50), Frijoles, secos (50), Maiz (50)
Código del año	desconocido	0 (0.0%)	25	2000 (15), 2001 (15), 2002 (15)
Año	temporal	0 (0.0%)	25	2000 (15), 2001 (15), 2002 (15)
Unidad	categorico	0 (0.0%)	2	toneladas (199), kg/ha (175)
Valor	numerico	0 (0.0%)	374	min 624.4 · máx 3706563.0 · media 745993.394 · atipicos 0 (0.0%)

FAOSTAT – SEGURIDAD ALIMENTARIA – 1.138 REGISTROS

CAMPO	TIPO	MULOS	ÚNICOS	DETALLE
Código del ámbito	desconocido	0 (0.0%)	1	FS (1138)
Ámbito	desconocido	0 (0.0%)	1	Datos de Seguridad Alimentaria (1138)
Código del área	desconocido	0 (0.0%)	1	44 (1138)
Área	categorico	0 (0.0%)	1	Colombia (1138)
Código del elemento	desconocido	0 (0.0%)	10	6121 (451), 6132 (208), 6128 (124)
Elemento	categorico	0 (0.0%)	3	Valor (898), Confidence interval: Lower bound (420), Confidence interval: Upper bound (1420)

				bound (120), confidence interval: upper bound (120)
Código del producto	desconocido	0 (0.0%)	47	210401 (30), 210401M (30), 210401F (30)
Producto	categorico	0 (0.0%)	47	Prevalencia de la inseguridad alimentaria grave en la población total (%) (promedio de 3 años) (30), Prevalencia de la inseguridad alimentaria grave en la población adulta masculina (%) (promedio de 3 años) (30), Prevalencia de la inseguridad alimentaria grave en la población adulta femenina (%) (promedio de 3 años) (30)
Código del año	desconocido	0 (0.0%)	50	20142016 (47), 20152017 (47), 20162018 (47)
Año	temporal	0 (0.0%)	50	2014-2016 (47), 2015-2017 (47), 2016-2018 (47)
Unidad	categorico	0 (0.0%)	6	% (571), millones de No. (328), kcal/persona/día (124)
Valor	numerico	0 (0.0%)	498	min 0.1 · máx 18477.0 · media 566.574 · atipicos 125 (11.0%)

Captura — sección "Perfilamiento" de /r2, tabla de eva_basicos con tipo, nulos, únicos y detalle por columna.

6 • Evaluación de las dimensiones de calidad

Fórmulas en `app/quality.py::compute_dimensions`. Valores medidos sobre la versión cruda (antes del tratamiento):

Dataset	Compleitud	Exactitud	Consistencia	Unicidad	Validez	Actualidad
eva_basicos	100%	99.91%	86.31%	100%	88.04%	80%
qcl	99.25%	35.15%	99.73%	99.73%	100%	80%
qcl_basicos	100%	35.15%	100%	100%	100%	80%
fs	100%	100%	100%	100%	100%	93.33%

Fórmulas e interpretación

- **Compleitud** = $100 \times (1 - \text{nulos_críticos} / (\text{n_filas} \times \text{n_campos_críticos}))$. EVA: 0 nulos en sus 7 campos críticos → 100%.
- **Unicidad** = $100 \times (\text{n_filas} - \text{duplicados_bajo_llave}) / \text{n_filas}$. qcl con la llave original de R1 (sin Unidad): 99.73% — 25 combinaciones "duplicadas" que en realidad son el mismo indicador reportado en dos unidades (ver sección 9).
- **Validez** = $100 \times (1 - \text{filas_con_violación_de_rango/dominio/patrón} / \text{n_filas})$. EVA: 88.04%, porque 5.854 filas (11.96%) tienen `CodigoMunicipioDane` sin el cero inicial.
- **Exactitud**: EVA compara `Producción / AreaCosechada` (calculado) vs. `Rendimiento` (reportado), tolerancia 1% → 99.91%. qcl / qcl_basicos: $100 - \text{promedio}(|\text{Diferencia_pct}|)$ del cruce EVA↔FAOSTAT → 35.15%, reflejando divergencias metodológicas ya documentadas. fs: % de grupos con `Lower bound ≤ Valor ≤ Upper bound` → 100%.
- **Consistencia**: EVA compara `AreaCosechada` vs. `AreaSembrada` → 86.31%. FAOSTAT compara `Unidad` contra la modal de su (Producto, Elemento) → 99.73% en qcl.
- **Actualidad** = $100 \times \max(0, 1 - \text{antigüedad_años} / \text{ventana})$. EVA/QCL: último año 2024, ventana 10 → 80%. fs: ventana 15 (rezago SOFI) → 93.33%.

Interpretación general: las 4 fuentes cumplen la mayoría de los requisitos definidos en la sección 4; las dos excepciones (validez de EVA y exactitud de qcl/qcl_basicos) tienen causa raíz identificada y se retoman en las secciones 8 y 10.


3 · DIMENSIONES DE CALIDAD, MÉTRICAS Y REQUISITOS

Se evalúan las 6 dimensiones exigidas — completitud, exactitud, consistencia, unicidad, validez y actualidad— con una fórmula verificable por dimensión (ver `app/quality.py::compute_dimensions`). El requisito mínimo de cada dimensión se definió según el uso previsto (sección 1): identificadores y valores críticos casi sin nulos ni duplicados, vigencia razonable frente a un rezago administrativo típico de fuentes agropecuarias oficiales. Cuando una dimensión no tiene mecanismo de contraste disponible para un dataset, se muestra "No aplica" — nunca se inventa un número.

EVA – PRODUCCIÓN MUNICIPAL



FAOSTAT – TODOS LOS PRODUCTOS



FAOSTAT – CULTIVOS BÁSICOS



FAOSTAT – SEGURIDAD ALIMENTARIA



Captura — sección "Dimensiones de calidad, métricas y requisitos" de /r2, con barras y cumplimiento por dataset.

7 • Inventario de problemas encontrados

12 problemas identificados sobre la versión cruda de los 4 datasets, generados por `app/quality.py::build_problem_inventory`. Nivel de impacto según `nivel_impacto()`: Alto si el campo es crítico y $\geq 10\%$ de registros afectados; Medio si es crítico y $\geq 2\%$ (o no crítico y $\geq 20\%$); Bajo en el resto.

#	Dataset	Variable	Afectados	%	Dimensión	Impacto
1	qcl	Valor	280	3.02%	Compleitud	Medio
2	eva_basicos	CodigoDeptoDane	5.854	11.96%	Validez	Bajo
3	eva_basicos	CodigoMunicipioDane	5.854	11.96%	Validez	Alto
4	eva_basicos	AreaSembrada	6.288	12.85%	Exactitud	Alto
5	eva_basicos	AreaCosechada	6.505	13.29%	Exactitud	Alto
6	eva_basicos	Produccion	7.368	15.06%	Exactitud	Alto
7	eva_basicos	Rendimiento	3.342	6.83%	Exactitud	Medio
8	eva_basicos	AreaCosechada / AreaSembrada	6.700	13.69%	Consistencia	Alto
9	qcl_basicos	Valor (por Producto/Elemento)	7	1.87%	Exactitud	Bajo
10	qcl	Producto / Unidad	50	0.54%	Unicidad	Bajo*
11	qcl	Valor (por Producto/Elemento)	327	3.64%	Exactitud	Medio
12	fs	Valor (por Producto/Elemento)	3	0.26%	Exactitud	Bajo

* El hallazgo #10 tiene impacto numérico bajo por volumen, pero se destaca aparte porque invalida un supuesto de R1: los "25 duplicados" que se reportaban en `qcl` no eran errores de datos, sino el mismo indicador reportado en dos unidades (huevos en toneladas y en miles de unidades) bajo una llave de verificación incompleta.

4 · INVENTARIO DE PROBLEMAS

12 problemas identificados en la versión cruda de los 4 datasets: **5 DE IMPACTO ALTO** **3 MEDIO** **4 BAJO**. El nivel de impacto combina el % de registros afectados con si el campo alimenta directamente el análisis (regla en `app/quality.py::nivel_impacto`, ver anexo del informe técnico).

FAOSTAT – TODOS LOS PRODUCTOS

Valor

IMPACTO MEDIO

280 valores nulos o vacíos en 'Valor'.

REGISTROS AFECTADOS

280 (3.02%)

DIMENSIÓN

Compleitud

CAUSA PROBABLE

Ausencia de reporte o de validación de campo obligatorio en la fuente.

EVIDENCIA

`app.quality.profile_columns('qcl')['Valor'].n_nulos`

EVA – PRODUCCIÓN MUNICIPAL

CodigoDeptoDane

IMPACTO BAJO

5854 valores que no cumplen el formato esperado en 'CodigoDeptoDane'.

REGISTROS AFECTADOS

5.854 (11.96%)

DIMENSIÓN

Validez

CAUSA PROBABLE

Formato inconsistente entre fuentes o entre periodos de carga.

EVIDENCIA

`app.quality.profile_columns('eva_basicos')['CodigoDeptoDane'].no_conforme_patron`

EVA – PRODUCCIÓN MUNICIPAL

CodigoMunicipioDane

IMPACTO ALTO

5854 valores que no cumplen el formato esperado en 'CodigoMunicipioDane'.

REGISTROS AFECTADOS

5.854 (11.96%)

DIMENSIÓN

Validez

CAUSA PROBABLE

Formato inconsistente entre fuentes o entre periodos de carga.

EVIDENCIA

`app.quality.profile_columns('eva_basicos')['CodigoMunicipioDane'].no_conforme_patron`

EVA – PRODUCCIÓN MUNICIPAL

AreaSembrada

IMPACTO ALTO

6288 valores atípicos ($\pm 1.5 \times \text{RIC}$) en 'AreaSembrada'.

REGISTROS AFECTADOS

6.288 (12.85%)

DIMENSIÓN

Exactitud

CAUSA PROBABLE

Variabilidad real del fenómeno (municipios/productos de gran escala) o error de captura puntual — requiere revisión caso a caso, no se elimina automáticamente.

EVIDENCIA

`app.quality.profile_columns('eva_basicos')['AreaSembrada'].outliers_iqr`

EVA – PRODUCCIÓN MUNICIPAL

AreaCosechada

IMPACTO ALTO

6505 valores atípicos ($\pm 1.5 \times \text{RIC}$) en 'AreaCosechada'.

REGISTROS AFECTADOS

6.505 (13.29%)

DIMENSIÓN

Exactitud

CAUSA PROBABLE

Variabilidad real del fenómeno (municipios/productos de gran escala) o error de captura puntual — requiere revisión caso a caso, no se elimina automáticamente.

EVIDENCIA

`app.quality.profile_columns('eva_basicos')['AreaCosechada'].outliers_iqr`

EVA – PRODUCCIÓN MUNICIPAL

Produccion

IMPACTO ALTO

7368 valores atípicos ($\pm 1.5 \times \text{RIC}$) en 'Produccion'.

REGISTROS AFECTADOS
7.368 (15.06%)

DIMENSIÓN
Exactitud

CAUSA PROBABLE
Variabilidad real del fenómeno (municipios/productos de gran escala) o error de captura puntual — requiere revisión caso a caso, no se elimina automáticamente.

EVIDENCIA
`app.quality.profile_columns('eva_basicos').outliers_iqr`

EVA – PRODUCCIÓN MUNICIPAL

Rendimiento

IMPACTO MEDIO

3342 valores atípicos ($\pm 1.5 \times \text{RIC}$) en 'Rendimiento'.

REGISTROS AFECTADOS
3.342 (6.83%)

DIMENSIÓN
Exactitud

CAUSA PROBABLE
Variabilidad real del fenómeno (municipios/productos de gran escala) o error de captura puntual — requiere revisión caso a caso, no se elimina automáticamente.

EVIDENCIA
`app.quality.profile_columns('eva_basicos').outliers_iqr`

EVA – PRODUCCIÓN MUNICIPAL

AreaCosechada / AreaSembrada

IMPACTO ALTO

6700 registros reportan área cosechada mayor que el área sembrada en el mismo semestre.

REGISTROS AFECTADOS
6.700 (13.69%)

DIMENSIÓN
Consistencia

CAUSA PROBABLE
Posible re-siembra dentro del mismo semestre o error de reporte municipal (autorreporte sin validación cruzada).

EVIDENCIA
`app.quality._consistencia_area_vs_sembrada sobre eva_basicos.json`

FAOSTAT – SEGURIDAD ALIMENTARIA

Valor (por Producto, Elemento)

IMPACTO BAJO

3 de 1134 valores evaluables son atípicos ($\pm 1.5 \times \text{RIC}$) dentro de su propia serie (Producto, Elemento) — no se calculó globalmente para no mezclar magnitudes distintas (toneladas, cabezas, kg/ha, %, etc.).

REGISTROS AFECTADOS
3 (0.26%)

DIMENSIÓN
Exactitud

CAUSA PROBABLE
Variabilidad real de la serie (años atípicos por clima o mercado) o error de captura puntual — requiere revisión caso a caso.

EVIDENCIA
`app.quality._outliers_grupo_iqr sobre fs.json, agrupado por (Producto, Elemento)`

FAOSTAT – CULTIVOS BÁSICOS

Valor (por Producto, Elemento)

IMPACTO BAJO

7 de 374 valores evaluables son atípicos ($\pm 1.5 \times \text{RIC}$) dentro de su propia serie (Producto, Elemento) — no se calculó globalmente para no mezclar magnitudes distintas (toneladas, cabezas, kg/ha, %, etc.).

REGISTROS AFECTADOS
7 (1.87%)

DIMENSIÓN
Exactitud

CAUSA PROBABLE
Variabilidad real de la serie (años atípicos por clima o mercado) o error de captura puntual — requiere revisión caso a caso.

EVIDENCIA
`app.quality._outliers_grupo_iqr sobre qcl_basicos.json, agrupado por (Producto, Elemento)`

FAOSTAT – TODOS LOS PRODUCTOS

Producto / Unidad

IMPACTO BAJO

25 combinaciones (Área,Producto,Elemento,Año) reportan el mismo indicador en más de una Unidad (p. ej. huevos en 'toneladas' y en '1000 No.'), afectando 50 filas; la llave de unicidad original de R1 (sin 'Unidad') las contaba como duplicados.

REGISTROS AFECTADOS

DIMENSIÓN

CAUSA PROBABLE

EVIDENCIA

50 (0.54%)

Unidad

Definición de llave de unicidad incompleta: no se incluyó 'Unidad' al validar duplicados en R1.

app.quality._hallazgo_duplicados_por_unidad sobre qcl.json

FAOSTAT - TODOS LOS PRODUCTOS

Valor (por Producto, Elemento)

IMPACTO MEDIO

327 de 8994 valores evaluables son atípicos ($\pm 1.5 \times \text{RIC}$) dentro de su propia serie (Producto, Elemento) — no se calculó globalmente para no mezclar magnitudes distintas (toneladas, cabezas, kg/ha, %, etc.).

REGISTROS AFECTADOS

327 (3.64%)

DIMENSIÓN

Exactitud

CAUSA PROBABLE

Variabilidad real de la serie (años atípicos por clima o mercado) o error de captura puntual — requiere revisión caso a caso.

EVIDENCIA

app.quality._outliers_grupo_iqr sobre qcl.json, agrupado por (Producto, Elemento)

Captura — sección "Inventario de problemas" de /r2, tarjetas con variable, descripción, registros afectados, dimensión, impacto y causa probable.

8 · Análisis de las causas

- **Ausencia de validaciones en el origen:** los 280 nulos de `Valor` en `qc1` son series de FAOSTAT que no se midieron ese año; no existe un valor "correcto" que imputar.
- **Autorreporte municipal sin validación cruzada:** el 13.69% de incoherencias área cosechada/sembrada en EVA sugiere que ningún control impide que un municipio reporte una re-siembra o un error de captura antes de publicarse.
- **Definición de llave de unicidad incompleta (defecto de R1):** las 25 combinaciones de huevos en dos unidades se contaban como "duplicados" porque la llave de verificación de R1 no incluía `Unidad` — error de diseño de la validación, no del dato.
- **Conversión automática de tipos por la herramienta de procesamiento:** el CSV original de EVA sí trae los códigos DANE con cero inicial como texto (p. ej. "05001"); al construir `eva_basicos.json` en R1, la inferencia automática de tipos de `pandas` los convirtió a entero y perdió el cero inicial en los departamentos 01-09, afectando el 11.96% de las filas.
- **Heterogeneidad legítima de fuentes:** FAOSTAT reporta el mismo `Elemento` en unidades distintas según si el producto es un cultivo o una especie pecuaria — exige agrupar por (Producto, Elemento) al calcular cualquier estadístico sobre `Valor`.
- **Falta de actualización:** ningún dataset tiene datos posteriores a 2024; la dimensión actualidad lo refleja con una fórmula explícita de antigüedad frente a la fecha de este entregable.

5 · ANÁLISIS DE CAUSAS

- **Ausencia de validaciones en el origen:** los 280 valores nulos de `Valor` en `qc1` reflejan series de FAOSTAT que simplemente no se midieron ese año — no hay un valor "correcto" que imputar, y la fuente no impone un mínimo de cobertura temporal por serie.
- **Autorreporte municipal sin validación cruzada:** el 13.69% de las filas de EVA con área cosechada mayor que la sembrada sugiere que ningún control impide que un municipio reporte una re-siembra o un error de captura sin que el sistema lo detecte antes de publicarse.
- **Definición de llave de unicidad incompleta (defecto de R1):** las 25 combinaciones de huevos reportadas en dos unidades (toneladas y 1000 unidades) se contaban como "duplicados" en R1 porque la llave de verificación no incluía `Unidad` — un error de diseño de la validación, no del dato.
- **Conversión automática de tipos por la herramienta de procesamiento:** el CSV original de EVA sí trae los códigos DANE con cero inicial como texto (p. ej. "05001"); al construir `eva_basicos.json` en R1, la inferencia automática de tipos de `pandas` los convirtió a entero y perdió el cero inicial en los departamentos 01-09, afectando el 11.96% de las filas — un defecto real del pipeline, no del dato fuente.
- **Duplicidad/heterogeneidad legítima de fuentes:** FAOSTAT reporta el mismo `Elemento` (p. ej. "Producción") en unidades distintas según si el producto es un cultivo o una especie pecuaria — no es un error, pero exige agrupar por (Producto, Elemento) al calcular cualquier estadístico sobre `Valor`, algo que el diagnóstico inicial de R1 no hacía.
- **Falta de actualización:** ningún dataset tiene datos posteriores a 2024; frente a la fecha de este entregable (2026), la actualidad medida (dimensión 6) refleja ese rezago con una fórmula explícita de antigüedad, no con una etiqueta subjetiva.

Captura — sección "Causas probables" de /r2.

9 • Integración y homologación de los datos

La homologación de nombres de cultivo entre EVA y FAOSTAT ya se resolvió en R1 (`CROP_MAPPING` , en `scripts/process_eva.py`), reutilizada sin cambios por el tratamiento:

Cultivo (EVA)	Producto (FAOSTAT)
Maíz	Maíz
Arroz	Arroz
Papa	Papas, patatas
Plátano	Plátanos (Verde) y bananos para cocinar
Yuca	Yuca, fresca
Frijol	Frijoles, secos

R2 añade dos correcciones de esquema adicionales, también de integración/homologación:

- **Llave de unicidad ampliada en FAOSTAT** (+ `Unidad`): homologa el criterio de identidad de fila entre datasets que antes lo tenían incompleto.
- **Formato de código DANE homogéneo** (texto de ancho fijo, 2 y 5 dígitos): homologa la representación para que sea comparable con cualquier otra fuente oficial que use el estándar DANE.
- `AnioNormalizado` en los 3 datasets FAOSTAT: homologa el formato temporal (año puntual vs. trienio) sin destruir el campo `Año` original.

6 · INTEGRACIÓN Y HOMOLOGACIÓN

La homologación entre EVA y FAOSTAT ya se resolvió en R1 mediante un cruce de nombres de cultivo (`CROP_MAPPING`, en `scripts/process_eva.py`), reutilizado sin cambios por el tratamiento de esta etapa:

CULTIVO (EVA)	PRODUCTO (FAOSTAT)
Maiz	Maiz
Arroz	Arroz
Papa	Papas, patatas
Plátano	Plátanos (Verde) y bananos para cocinar
Yuca	Yuca, fresca
Frijol	Frijoles, secos

A esa homologación de categorías, R2 añade dos correcciones de esquema que también son integración/homologación en sentido estricto:

- **Llave de unicidad ampliada en FAOSTAT (+ Unidad):** homologa el criterio de identidad de fila entre datasets que antes lo tenían incompleto.
- **Formato de código DANE homogéneo** (texto de ancho fijo, 2 y 5 dígitos): homologa la representación de `CodigoDeptoDane/CodigoMunicipioDane` para que sea comparable con cualquier otra fuente oficial que use el estándar DANE (ENSIN, DANE-IPC).
- **AnioNormalizado** en los 3 datasets FAOSTAT: homologa el formato temporal (año puntual vs. trienio) sin destruir el campo `Año` original.

Captura — sección "Integración y homologación" de /r2.

10 • Plan de tratamiento

Ejecutado por `scripts/clean_datasets.py`, que lee la versión cruda de R1 y escribe la versión tratada en `app/static/data/R2/*.json` + `log_tratamiento.json`. **Regla general: ningún registro se elimina y ningún valor se fabrica** — lo corregible sin ambigüedad se corrige (tipos, llave de unicidad, fechas); lo demás se marca con una bandera nueva (`_flag_*`, `_outlier_*`) para que el análisis aguas abajo decida cómo tratarlo. Justificación de cada decisión:

Acción	Datasets	Decisión	Justificación
Corrección de la llave de unicidad (+Unidad)	qcl, qcl_basicos, fs	Corrección	25 combinaciones reportaban el mismo indicador en 2 unidades; no eran duplicados reales, se corrige la llave sin borrar filas.
Nulos en 'Valor'	qcl	Flag	No se fabrica un valor que FAOSTAT no reportó; se excluye de agregaciones vía bandera.
Estandarización de fechas (AnioNormalizado)	qcl, qcl_basicos, fs	Corrección	Año puntual vs. trienio unificado en un campo nuevo, sin destruir el original.
Atípicos en 'Valor' ($\pm 1.5 \times \text{RIC}$ por Producto/Elemento)	qcl, qcl_basicos, fs	Flag	Variabilidad real de la serie o error puntual — requiere revisión caso a caso.
Corrección de tipos (códigos DANE)	eva_basicos	Corrección	5.854 registros sin cero inicial por defecto del pipeline de R1; se reformatea el tipo, el valor no cambia.
Validación de rangos ($\text{AreaCosechada} \leq \text{AreaSembrada}$)	eva_basicos	Flag	No hay forma no ambigua de saber cuál campo es el erróneo (podría ser resiembra legítima).
Atípicos en área/producción/rendimiento ($\pm 1.5 \times \text{RIC}$)	eva_basicos	Flag	Valores altos en municipios/cultivos de gran escala son datos reales, no errores.

27 acciones aplicadas en total (detalle completo en `log_tratamiento.json`).

Comparación antes / después

Dataset	Dimensión	Antes	Después	Qué cambió
qcl	Unicidad	99.73%	100%	Se corrigió la llave de unicidad (+Unidad)

Dataset	Dimensión	Antes	Después	Qué cambió
eva_basicos	Validez	88.04%	100%	Se corrigieron los códigos DANE

El resto de dimensiones permanece igual antes/después por diseño (política de "flag, no fabricar"): p. ej. la consistencia de `eva_basicos` sigue en 86.31% porque las 6.700 filas con área cosechada > sembrada quedan marcadas pero no se corrigen.

7 · PLAN DE TRATAMIENTO APLICADO

Ejecutado por `scripts/clean_datasets.py` sobre la versión cruda (R1) de los 4 datasets, generando la versión tratada en `app/static/data/R2/`. Regla general: **ningún registro se elimina y ningún valor se fabrica**; lo corregible sin ambigüedad se corrige (tipos, llave de unicidad, fechas), lo demás se marca con una bandera nueva para que el análisis aguas abajo decida cómo tratarlo.

EVA – PRODUCCIÓN MUNICIPAL

ACCIÓN	REGISTROS AFECTADOS	DECISIÓN	JUSTIFICACIÓN
Eliminación de duplicados	0	SIN_ACCION	Se verificó la llave (municipio, cultivo, desagregación, año, periodo); no se encontraron filas duplicadas para eliminar.
Tratamiento de valores nulos	0	SIN_ACCION	No se encontraron valores nulos en las variables numéricas críticas; no se requirió imputación ni eliminación.
Estandarización de texto (espacios/casing)	0	SIN_ACCION	Se recorta espacio en blanco y se colapsan espacios dobles en campos de texto y categóricos; en este corte no se encontraron variantes (la fuente ya llega curada), el control queda activo para futuros refrescos del dataset.
Corrección de tipos de datos (códigos DANE con cero inicial)	5.854	CORRECCION	5854 registros tenían 'CodigoMunicipioDane'/'CodigoDeptoD...' sin el cero inicial (se guardaron como entero al construir el JSON de R1); se reformatean como texto de ancho fijo (2 y 5 dígitos) – el valor no cambia, solo su representación.
Validación de rangos (AreaCosechada ≤ AreaSembrada)	6.700	FLAG	6700 registros incumplen la regla; se marcan con '_flag_area_incoherente' porque no hay forma no ambigua de saber cuál campo es el erróneo (podría ser resiembra legítima en el mismo semestre) – no se fabrica un valor corregido.
Tratamiento justificado de atípicos en 'AreaSembrada' ($\pm 1.5 \times \text{RIC}$)	6.288	FLAG	6288 valores fuera de [-257.64, 456.06]; se marcan con '_outlier_iqr_AreaSembrada' y NO se eliminan – valores altos en municipios o cultivos de gran escala son datos reales, no errores de captura.
Tratamiento justificado de atípicos en 'AreaCosechada' ($\pm 1.5 \times \text{RIC}$)	6.505	FLAG	6505 valores fuera de [-227.0, 405.0]; se marcan con '_outlier_iqr_AreaCosechada' y NO se eliminan – valores altos en municipios o cultivos de gran escala son datos reales, no errores de captura.
Tratamiento justificado de atípicos en 'Produccion' ($\pm 1.5 \times \text{RIC}$)	7.368	FLAG	7368 valores fuera de [-1165.5, 1998.5]; se marcan con '_outlier_iqr_Produccion' y NO se eliminan – valores altos en municipios o cultivos de gran escala son datos reales, no errores de captura.

Tratamiento justificado de atípicos en 'Rendimiento' ($\pm 1.5 \times \text{RIC}$) 3.342

FLAG

3342 valores fuera de [-8.5, 17.9]; se marcan con '_outlier_iqr_Rendimiento' y NO se eliminan – valores altos en municipios o cultivos de gran escala son datos reales, no errores de captura.

FAOSTAT – TODOS LOS PRODUCTOS

ACCIÓN	REGISTROS AFECTADOS	DECISIÓN	JUSTIFICACIÓN
Corrección de la llave de unicidad (+ 'Unidad')	50	CORRECCION_LLAVE	25 combinaciones (Área, Producto, Elemento, Año) reportaban el mismo indicador en más de una Unidad y se contaban como 'duplicadas' con la llave original de R1. Se corrige agregando 'Unidad' a la llave de unicidad – no se elimina ninguna fila, eran datos válidos.
Tratamiento de valores nulos en 'Valor'	280	FLAG	280 filas sin 'Valor' reportado; se marcan con '_flag_valor_nulo' y se excluyen de agregaciones, pero se conservan (no se fabrica un valor que FAOSTAT no reportó).
Estandarización de texto (espacios/casing)	0	SIN_ACCION	Se recorta espacio en blanco y se colapsan espacios dobles; en este corte no se encontraron variantes, el control queda activo para futuros refrescos.
Estandarización de fechas (AnioNormalizado)	9.274	CORRECCION	Se añade 'AnioNormalizado' (año entero) a partir de 'Año', que en FAOSTAT puede venir como año puntual o como trienio (p. ej. '2000-2002'); el campo original se conserva sin modificar.
Homologación/consistencia de unidad por producto y elemento	25	FLAG	25 filas usan, para su combinación (Producto, Elemento), una Unidad distinta a la modal; se marcan con '_flag_unidad_atipica' para revisión, sin alterar el valor reportado.
Tratamiento justificado de atípicos en 'Valor' ($\pm 1.5 \times \text{RIC}$ por Producto/Elemento)	327	FLAG	327 valores atípicos dentro de su propia serie (Producto, Elemento); se marcan con '_outlier_iqr_valor' y NO se eliminan – variabilidad real de la serie (clima, mercado) o error puntual, requiere revisión caso a caso.

FAOSTAT – CULTIVOS BÁSICOS

ACCIÓN	REGISTROS AFECTADOS	DECISIÓN	JUSTIFICACIÓN
Corrección de la llave de unicidad (+ 'Unidad')	0	CORRECCION_LLAVE	No se encontraron combinaciones ambiguas de Unidad para este dataset.
Tratamiento de valores nulos en 'Valor'	0	SIN_ACCION	No se encontraron valores nulos en 'Valor'.
Estandarización de texto	0	SIN_ACCION	Se recorta espacio en blanco y se

(espacios/casing)			colapsan espacios dobles; en este corte no se encontraron variantes, el control queda activo para futuros refrescos.
Estandarización de fechas (AnioNormalizado)	374	CORRECCION	Se añade 'AnioNormalizado' (año entero) a partir de 'Año', que en FAOSTAT puede venir como año puntual o como trienio (p. ej. '2000-2002'); el campo original se conserva sin modificar.
Homologación/consistencia de unidad por producto y elemento	0	SIN_ACCION	Todas las filas usan la Unidad modal de su combinación (Producto, Elemento).
Tratamiento justificado de atípicos en 'Valor' ($\pm 1.5 \times \text{RIC}$ por Producto/Elemento)	7	FLAG	7 valores atípicos dentro de su propia serie (Producto, Elemento); se marcan con '_outlier_iqr_valor' y NO se eliminan – variabilidad real de la serie (clima, mercado) o error puntual, requiere revisión caso a caso.


FAOSTAT – SEGURIDAD ALIMENTARIA

ACCIÓN	REGISTROS AFECTADOS	DECISIÓN	JUSTIFICACIÓN
Corrección de la llave de unicidad (+ 'Unidad')	0	CORRECCION_LLAVE	No se encontraron combinaciones ambiguas de Unidad para este dataset.
Tratamiento de valores nulos en 'Valor'	0	SIN_ACCION	No se encontraron valores nulos en 'Valor'.
Estandarización de texto (espacios/casing)	0	SIN_ACCION	Se recorta espacio en blanco y se colapsan espacios dobles; en este corte no se encontraron variantes, el control queda activo para futuros refrescos.
Estandarización de fechas (AnioNormalizado)	1.138	CORRECCION	Se añade 'AnioNormalizado' (año entero) a partir de 'Año', que en FAOSTAT puede venir como año puntual o como trienio (p. ej. '2000-2002'); el campo original se conserva sin modificar.
Homologación/consistencia de unidad por producto y elemento	0	SIN_ACCION	Todas las filas usan la Unidad modal de su combinación (Producto, Elemento).
Tratamiento justificado de atípicos en 'Valor' ($\pm 1.5 \times \text{RIC}$ por Producto/Elemento)	3	FLAG	3 valores atípicos dentro de su propia serie (Producto, Elemento); se marcan con '_outlier_iqr_valor' y NO se eliminan – variabilidad real de la serie (clima, mercado) o error puntual, requiere revisión caso a caso.

Captura — sección "Plan de tratamiento aplicado" de /r2.

8 · COMPARACIÓN ANTES / DESPUÉS

Como el tratamiento marca en vez de corregir en silencio, la mayoría de las 6 dimensiones no cambia numéricamente entre la versión cruda y la tratada — eso es intencional, no un error: el objetivo no era "subir el número" sino volver visibles y trazables problemas que antes no lo eran. Dos excepciones sí muestran una mejora real y medible: la **unicidad de qc1** (99.73% → 100%, al corregir la llave de unicidad) y la **validez de eva_basicos** (88.04% → 100%, al corregir el formato de los códigos DANE).



EVA – PRODUCCIÓN MUNICIPAL

DIMENSIÓN	ANTES	DESPUÉS	Δ
Completitud	100.0%	100.0%	0.0
Exactitud	99.91%	99.91%	0.0
Consistencia	86.31%	86.31%	0.0
Unicidad	100.0%	100.0%	0.0
Validez	88.04%	100.0%	11.96
Actualidad	80.0%	80.0%	0.0

FAOSTAT – TODOS LOS PRODUCTOS

DIMENSIÓN	ANTES	DESPUÉS	Δ
Completitud	99.25%	99.25%	0.0
Exactitud	35.15%	35.15%	0.0
Consistencia	99.73%	99.73%	0.0
Unicidad	99.73%	100.0%	0.27
Validez	100.0%	100.0%	0.0
Actualidad	80.0%	80.0%	0.0

FAOSTAT – CULTIVOS BÁSICOS

DIMENSIÓN	ANTES	DESPUÉS	Δ
Completitud	100.0%	100.0%	0.0
Exactitud	35.15%	35.15%	0.0

Exactitud	88.10%	88.10%	0.0
Consistencia	100.0%	100.0%	0.0
Unicidad	100.0%	100.0%	0.0
Validez	100.0%	100.0%	0.0
Actualidad	80.0%	80.0%	0.0
FAOSTAT – SEGURIDAD ALIMENTARIA			
DIMENSIÓN	ANTES	DESPUÉS	Δ
Compleitud	100.0%	100.0%	0.0
Exactitud	100.0%	100.0%	0.0
Consistencia	100.0%	100.0%	0.0
Unicidad	100.0%	100.0%	0.0
Validez	100.0%	100.0%	0.0
Actualidad	93.33%	93.33%	0.0

Captura — sección "Comparación antes/después" de /r2, gráfico y tabla por dataset.

11 • Implementación en Flask

Paso a paso de la integración en la aplicación web:

1. **Módulo de lógica** — `app/quality.py`: esquemas de dataset, perfilamiento, 6 dimensiones, inventario de problemas (Python puro, sin Flask).
2. **Script de tratamiento** — `scripts/clean_datasets.py`: lee `app/static/data/R1/`, aplica el tratamiento, escribe `app/static/data/R2/`.
3. **Rutas nuevas** — `app/routes/project.py`: `/r2`, `/api/profile/<name>`, y `version=crudo|tratado` en `/api/dataset/<name>`.
4. **Plantilla** — `app/templates/project/project/R2.html`: sección "Calidad de Datos" completa.
5. **Activación** — `app/etapas.py`: R2 pasa de "Próximamente" a "Completado" en el navbar y en `/entregables`.

Páginas desarrolladas y evidencias de funcionamiento



PROYECTO · MINERÍA DE DATOS

2000 - 2024

SEGURIDAD ALIMENTARIA Y PRODUCCIÓN AGRÍCOLA

Colombia produce en abundancia y, aun así, buena parte de sus territorios convive con inseguridad alimentaria. Este proyecto caracteriza —con datos oficiales, no con opinión— dónde, cuánto y con qué estabilidad se produce, para señalar los territorios más vulnerables en la disponibilidad de alimentos.

VER REPORTE R1 →

EXPLORAR LOS DATOS

1.104

MUNICIPIOS CUBIERTOS POR EVA (PRODUCCIÓN)

2000-2024

SERIE HISTÓRICA FAOSTAT ANALIZADA

6

CULTIVOS BÁSICOS DE LA CANASTA ALIMENTARIA



Proyecto académico del curso de Minería de Datos en la Universidad de Cundinamarca. Caracteriza la oferta de producción agrícola en Colombia y su relación con la disponibilidad de alimentos, a partir de fuentes oficiales abiertas.

PROYECTO

Inicio
Entregables
Reporte R1
Limitaciones

EQUIPO

Sobre nosotros
Jonathan David
Andrés Felipe
Universidad de Cundinamarca

FUENTES & API

Repositorio en GitHub
EVA - MinAgricultura/UPRA
FAOSTAT - FAO
[/api/dataset/qcL_basicos](#)
[/api/quality/fs](#)

ENTREGABLE · R2

DIAGNÓSTICO Y CALIDAD DE LOS DATOS

Perfilamiento, 6 dimensiones de calidad, inventario de problemas y tratamiento real aplicado a los 4 datasets de **Seguridad alimentaria y producción agrícola** (EVA municipal + 3 tablas FAOSTAT). Ningún registro se elimina ni se fabrica un valor: lo que no se puede corregir sin ambigüedad queda documentado como bandera.

4

DATASETS PERFILADOS Y TRATADOS

59.718

REGISTROS PERFILADOS EN TOTAL

12

PROBLEMAS EN EL INVENTARIO · 6 DE IMPACTO ALTO

27

ACCIONES DE TRATAMIENTO APLICADAS

Captura — encabezado del entregable R2 en "/r2", con estadísticas reales (4 datasets, registros perfilados, problemas detectados, acciones aplicadas).

ANEXO · EXPLORADOR CRUDO / TRATADO

Mismo explorador de R1, con un selector adicional para comparar la versión cruda (R1) con la tratada (R2). En "tratado" se agregan al final las columnas de bandera (`_flag_*`, `_outlier_*`) como evidencia directa de qué filas quedaron marcadas.

EVA — cultivos básicos (municipal)

Tratado (R2)

Buscar...

Todos

Todos

48.932 registros encontrados · página 1 de 6117

OHERENTE	_OUTLIER_IQR_AREASEMBRADA	_OUTLIER_IQR_AREACOSECHADA	_OUTLIER_IQR_PRODUCCIOM	_OUTLIER_IQR_RENDIMIENTO
No	No	No	No	No
Si	Si	No	No	No
Si	Si	No	No	No
Si	Si	No	No	No
Si	Si	No	No	No
Si	Si	No	No	No
Si	Si	No	No	No
Si	Si	No	No	No

← ANTERIOR

1 / 6117

SIGUIENTE →

Captura — explorador de datos de "/r2" con la versión "Tratado (R2)" seleccionada: se ven las columnas de bandera (`_outlier_iqr_*`) marcadas en rojo ("Sí") como evidencia directa de las filas tratadas.



■ HOJA DE RUTA DEL PROYECTO

OCHO ENTREGABLES, UN SOLO TERRITORIO

El proyecto avanza en ocho entregables, desde entender el problema hasta comunicar resultados accionables. Hoy solo **R1** está publicado; los demás aún no se han definido y se irán habilitando a medida que el curso avanza.

DISPONIBLE

Ver →

ENTREGABLE 1

R1-DEL PROBLEMA A LOS DATOS

Problema, preguntas analíticas, fuentes, dataset inicial, diccionario y diagnóstico de calidad.

DISPONIBLE

Ver →

ENTREGABLE 2

R2-DIAGNÓSTICO Y CALIDAD DE LOS DATOS

Perfilamiento, 6 dimensiones de calidad, inventario de problemas y tratamiento real aplicado a los 4 datasets (EVA + FAOSTAT).

PRÓXIMAMENTE

ENTREGABLE 3

R3-AÚN NO DEFINIDO

Este entregable todavía no se ha definido. Se documentará en una próxima etapa del curso.

PRÓXIMAMENTE

ENTREGABLE 4

R4-AÚN NO DEFINIDO

Este entregable todavía no se ha definido. Se documentará en una próxima etapa del curso.

PRÓXIMAMENTE

ENTREGABLE 5

R5-AÚN NO DEFINIDO

Este entregable todavía no se ha definido. Se documentará en una próxima etapa del curso.

PRÓXIMAMENTE

ENTREGABLE 6

R6-AÚN NO DEFINIDO

Este entregable todavía no se ha definido. Se documentará en una próxima etapa del curso.

PRÓXIMAMENTE

ENTREGABLE 7

R7-AÚN NO DEFINIDO

Este entregable todavía no se ha definido. Se documentará en una próxima etapa del curso.

PRÓXIMAMENTE

ENTREGABLE 8

R8-AÚN NO DEFINIDO

Este entregable todavía no se ha definido. Se documentará en una próxima etapa del curso.

 WOLOLO Proyecto académico del curso de Minería de Datos en la Universidad de Cundinamarca. Caracteriza la oferta de producción agrícola en Colombia y su relación con la disponibilidad de alimentos, a partir de fuentes oficiales abiertas.	PROYECTO Inicio Entregables Reporte R1 Limitaciones	EQUIPO Sobre nosotros Jonathan David Andrés Felipe Universidad de Cundinamarca	FUENTES & API Repositorio en GitHub EVA - MinAgricultura/UPRA FAOSTAT - FAO /api/dataset/qcL_basicos /api/quality/fs
© 2026 Wololo — Seguridad alimentaria y producción agrícola. Datos: FAO / MinAgricultura, uso académico.		Construido con Flask · Chart.js · Neumorfismo	

Captura — página "/entregables", hoja de ruta de las 8 etapas, con R2 marcado como completado.

■ ENTREGABLE · R1 · DEL PROBLEMA A LOS DATOS

DEL PROBLEMA A LOS DATOS

Tema: **Seguridad alimentaria y producción agrícola** · Cobertura: Colombia (nacional) · Periodo analizado: 2000 – 2024.

59.344
REGISTROS CONSOLIDADOS (EVA + FAOSTAT)

48.932
REGISTROS EVA · 1098 MUNICIPIOS

32
DEPARTAMENTOS CON DATOS EVA

4.1%
SUBALIMENTACIÓN COLOMBIA · 2023

Captura — encabezado del entregable R1 en "/r1", verificando que sigue funcionando sin regresión tras los cambios de R2.

12 • Gestión en GitHub

Todo el desarrollo se realizó en la rama `Feature/etapa-2`, creada desde `main`, con 9 commits identificables por unidad de trabajo (refactor, feature, fix, test, docs, perf), y se integró a `main` mediante un *pull request* revisado antes de fusionarse.

The screenshot shows the GitHub interface for the repository `JODACHSE / Minería-de-Datos`. The 'Branches' tab is selected, showing a list of branches. The 'main' branch is the default branch, and the 'Feature/etapa-2' branch is an active branch. The 'Feature/etapa-2' branch is linked to Pull Request #1.

Branch	Updated	Check status	Behind	Ahead	Pull request
main	1 hour ago				Default
Feature/etapa-2	1 hour ago		1	0	#1

Captura — GitHub, pestaña "Branches": `main` como rama por defecto y `Feature/etapa-2` vinculada al Pull Request #1.

Platform Solutions Resources Open Source Enterprise Pricing

Search / Sign in Sign up

JODACHSE / Minería-de-Datos Public

Code Issues Pull requests Actions Projects Security and quality Insights

Feature/etapa 2 #1

Merged N3X4N merged 9 commits into main from Feature/etapa-2 1 hour ago

Conversation 0 Commits 9 Checks 0 Files changed 18 +2.571 -129

N3X4N commented 2 days ago

No description provided.

N3X4N and others added 9 commits 2 days ago

- refactor: extraer DATASET_SCHEMA/compute_quality a app/quality.py 76959b4
- feat: perfilamiento, 6 dimensiones y script de tratamiento real (R2) 1e6f841
- fix: agrupar outliers e inconsistencia de unidad por Producto+Elemento a8e1639
- feat: entregable R2 - rutas, plantilla y grafico comparativo e920aee
- test: cobertura de perfilamiento, dimensiones y rutas de R2 eefd998
- docs: informe tecnico Etapa 2 y actualizar README con R2 28ce15d
- perf: acelerar /r2 (cache + elimina perfilamiento redundante de EVA) af1f712
- feat: Etapa 2 - diagnostico y calidad de los datos c0b88bb
- Merge branch 'Feature/etapa-2' of https://github.com/JODACHSE/Mineria... 63f0f10

Reviewers: No reviews

Assignees: No one assigned

Labels: None yet

Projects: None yet

Milestone: No milestone

Development: Successfully merging this pull request may close these issues. None yet

1 participant

Captura — GitHub, Pull Request #1 "Feature/etapa 2": estado **Merged**, 9 commits, 18 archivos modificados (+2.571 / -129 líneas).

Platform Solutions Resources Open Source Enterprise Pricing

Search / Sign in Sign up

JODACHSE / Minería-de-Datos Public

Code Issues Pull requests Actions Projects Security and quality Insights

Commits

main

All users All time

Commits on Sep 7, 2026

- Merge pull request #1 from JODACHSE/Feature/etapa-2 Verified e17acf6
- Merge branch 'Feature/etapa-2' of https://github.com/JODACHSE/Mineria-de-Datos into Feature/etapa-2 63f0f10
- feat: Etapa 2 - diagnostico y calidad de los datos c0b88bb

Commits on Sep 5, 2026

- perf: acelerar /r2 (cache + elimina perfilamiento redundante de EVA) af1f712
- docs: informe tecnico Etapa 2 y actualizar README con R2 28ce15d
- test: cobertura de perfilamiento, dimensiones y rutas de R2 eefd998
- feat: entregable R2 - rutas, plantilla y grafico comparativo e920aee

Captura — GitHub, historial de commits de **main** tras la fusión.

13 • Referencias bibliográficas

- FAO (2025). *FAOSTAT — Suite of Food Security Indicators & Crops and livestock products*. Organización de las Naciones Unidas para la Alimentación y la Agricultura. fao.org/faostat
- FAO — Voices of the Hungry (VoH). *Food Insecurity Experience Scale (FIES)*. fao.org/in-action/voices-of-the-hungry
- Ministerio de Agricultura y Desarrollo Rural / UPRA. *Evaluaciones Agropecuarias Municipales (EVA) 2019–2024*. Datos Abiertos Colombia. datos.gov.co
- ICBF, MinSalud, INS, Prosperidad Social (2015). *Encuesta Nacional de Situación Nutricional (ENSIN)*.
- DANE. *Índice de Precios al Consumidor (IPC), grupo Alimentos*. dane.gov.co
- Departamento Nacional de Planeación (DNP). *TerriData — Sistema de Estadísticas Territoriales*. terridata.dnp.gov.co
- World Bank Open Data. *Prevalence of undernourishment (% of population)*. data.worldbank.org
- Our World in Data. *Hunger and Undernourishment*. ourworldindata.org

14 · Enlaces del proyecto

Repositorio en GitHub	https://github.com/JODACHSE/Mineria-de-Datos
Pull Request de la Etapa 2	https://github.com/JODACHSE/Mineria-de-Datos/pull/1 (mergeado a <code>main</code>)
Aplicación publicada	[COMPLETAR — URL del servicio de despliegue, ej. https://wololo.onrender.com]
Entregable R2 en la app	/r2 (una vez publicada la URL anterior)

Pendiente antes de entregar: completar la URL de la aplicación publicada arriba, verificar en el navegador que `/`, `/r1`, `/r2` y `/entregables` cargan correctamente sobre esa URL (no solo en local), y confirmar que corresponde a la última versión de `main` (commit `e17acf6` o posterior).